

基于深度学习的 MBTI 人格与其语言风格的研究和预测

摘要：本文探讨了 MBTI 人格类型与文本语言风格之间的联系，并构建深度学习模型对用户的 MBTI 人格类型进行预测。研究基于大规模文本数据集，采用四种深度学习模型进行对比实验：长短期记忆网络(LSTM)、双向长短期记忆网络(Bi-LSTM)、带注意力机制的双向长短期记忆网络(Bi-LSTM+Attention)以及结合自适应学习率的带注意力机制的双向长短期记忆网络(Bi-LSTM+Attention+自适应学习率)，同时，研究还纳入了 SVM、XGBoost、Logistic Regression、CatBoost、Gradient Boosting、Random Forest、Multinomial Naive Bayes 等传统机器学习模型作为基准进行对比。最终结合了 Bi-LSTM、Attention 机制以及自适应学习率的模型在准确率和 F1 值等关键性能指标表现最佳，其准确率达到 0.9742。基于此设计了一个交互式前端系统，以实现依据用户输入的英文文本，预测其 MBTI 人格类型。

关键词：MBTI 人格类型；深度学习；双向长短期记忆网络；注意力机制；自适应学习率

Research and Prediction of MBTI Personality and Language Style Based on Deep Learning

Abstract: This paper explores the connection between MBTI personality type and text language style, and constructs a deep learning model to predict the user's MBTI personality type. Based on a large-scale text dataset, the study uses four deep learning models for comparative experiments: long short-term memory network (LSTM), bidirectional long short-term memory network (Bi-LSTM), bidirectional long short-term memory network with attention mechanism (Bi-LSTM+Attention), and bidirectional long short-term memory network with attention mechanism combined with adaptive learning rate (Bi-LSTM+Attention+Adaptive Learning Rate). At the same time, the study also includes traditional machine learning models such as SVM, XGBoost, Logistic Regression, CatBoost, Gradient Boosting, Random Forest, Multinomial Naive Bayes as benchmarks for comparison. In the end, the model that combines Bi-LSTM, Attention mechanism and adaptive learning rate performed best in key performance indicators such as accuracy and F1 value, with an accuracy of 0.9742. Based on this, an interactive front-end system is designed to predict the MBTI personality type of the user based on the English text entered by the user.

Keywords: MBTI personality type; deep learning; bidirectional long short-term memory network; attention mechanism; adaptive learning rate

目 录

摘 要.....	i
Abstract.....	ii
图目录.....	vi
表目录.....	vi
第一章 绪论.....	1
1.1 研究背景和意义.....	1
1.1.1 研究背景.....	1
1.1.2 研究的意义.....	1
1.2 国内外研究现状.....	2
1.2.1 MBTI 与语言风格研究.....	2
1.2.2 自然语言处理与深度学习技术.....	3
1.3 研究目标与内容.....	4
1.3.1 研究的目标.....	4
1.3.2 研究的主要内容.....	4
1.4 论文结构.....	5
第二章 相关工作.....	6
2.1 MBTI 人格理论.....	6
2.1.1 MBTI 人格类型概述.....	6
2.1.2 MBTI 四维度特征分析.....	6
2.1.3 MBTI 与语言行为的关联研究.....	7
2.2 自然语言处理技术.....	8
2.2.1 文本表示方法.....	8
2.2.2 词嵌入技术.....	10
2.2.3 文本特征提取.....	12
2.3 深度学习理论与方法.....	14
2.3.1 循环神经网络 (Recurrent Neural Network, RNN) 基础.....	14
2.3.2 LSTM 与变种模型.....	15
2.3.3 注意力机制原理.....	16
2.3.4 自适应学习率算法.....	18

第三章 研究方法设计	20
3.1 数据集构建与预处理	20
3.1.1 数据来源与介绍	20
3.1.2 数据集预处理流程	24
3.1.3 数据集划分策略	26
3.2 特征工程	26
3.2.1 语言学特征分析	26
3.2.2 文本表示模型选择	33
3.3 模型构建	34
3.3.1 LSTM 模型设计	34
3.3.2 Bi-LSTM 模型设计	35
3.3.3 Bi-LSTM+Attention 模型设计	36
3.3.4 Bi-LSTM+Attention+自适应学习率模型设计	38
3.3.5 传统机器学习模型实现	40
第四章 实验结果与分析	41
4.1 评估指标与实验环境	41
4.1.1 模型评估指标体系	41
4.1.2 实验环境配置	41
4.2 模型性能比较	42
4.3 MBTI 维度预测分析	43
第五章 人机交互系统设计与实现	45
5.1 系统设计目标与架构	45
5.1.1 系统功能需求分析	45
5.1.2 系统架构设计	45
5.1.3 数据流设计	45
5.2 前端界面设计与实现	46
5.2.1 前端交互功能实现	46
5.2.2 响应式设计适配	47
5.3 后端模型集成与部署	47
5.3.1 模型转换与优化	47
5.3.2 API 设计与实现	47

第六章 结论与展望	48
6.1 研究总结	48
6.2 局限性	48
6.3 未来研究方向	48
参考文献	49
致 谢	52
附 录	53
附录 1 系统主题	53
附录 2 系统处理流程	54

图目录

图 3.1 MBTI 类型分布	20
图 3.2 MBTI 四个维度占比	21
图 3.3 帖子总和长度箱线图	22
图 3.4 各 MBTI 类型平均问号和感叹号使用量对比	23
图 3.5 16 种人格类型词云图	24
图 3.6 MBTI 词性分布分析	27
图 3.7 MBTI 论述风格指标	29
图 3.8 MBTI 情感倾向	30
图 3.9 MBTI 时态使用	31
图 3.10 MBTI 特征词条形图	32
图 3.11 LSTM 训练结果	34
图 3.12 Bi-LSTM 训练结果	35
图 3.13 Bi-LSTM+Attention 5 折训练曲线	37
图 3.14 Bi-LSTM+Attention 混淆矩阵、ROC 曲线	37
图 3.15 最优模型训练过程	39
图 3.16 最优模型的分类报告、混淆矩阵	39
图 3.17 机器学习模型准确率对比	40
图 4.1 最优模型各维度准确率比较	43
图 4.2 最优模型维度混淆矩阵	44
图 4.3 最优模型各维度的 precision, recall 和 f1-score	44
图 5.1 MBTI 人格类型预测器	46

表目录

表 4.1 所有模型指标对比	42
----------------------	----

第一章 绪论

1.1 研究背景和意义

1.1.1 研究背景

人格特质反映出个体相对稳定的心理特征，包括认知模式、情感倾向、行为习惯等方面。这些特质对个人的判断、选择、社交互动和信息处理等产生的影响。在人格测评领域，迈尔斯-布里格斯性格类型指标（Myers-Briggs Type Indicator, MBTI）以荣格的心理类型理论《心理类型》^[1]为基础。其理论框架来源于大量临床实践的总结和提炼。随着社交媒体的普及，MBTI 相关话题引发了广泛讨论，部分平台相关内容的阅读量曾达到亿级^[2]。互联网用户产生的文本数据为研究语言特征与性格的关系提供了重要的素材。

人工智能的不断发展为心理特征的研究提供了新的可能。深度学习技术在自然语言理解领域的进步，使得从文本中提取心理特征^[3]成为可能。分析语言模式与 MBTI 维度之间的相关性，这不仅加深对人格特质的理解，还可开发实用的人格识别工具。

与传统的自我报告方法容易受到主观因素的影响相比，基于语言特征的分析更加客观。建立语言指标与人格维度之间的映射关系，既可以提高评估效率，还可以为心理语言学开辟新的研究方向。这种创新方法克服了传统评估的局限性，也拓展了人格研究的深度和范围。

1.1.2 研究的意义

本研究基于大量文本数据和深度学习技术，探讨 MBTI 人格特质与语言表达模式的关系。通过改进神经网络架构，采用动态注意力机制和自适应优化算法，有效解决了传统性格分类模型准确率不足、泛化能力差的问题。

基于此的 MBTI 预测系统在大量场景下具有适用价值。在商业领域，该系统可以深入分析用户内容（如评论、社交互动等），克服传统人口统计分析的局限性，揭示性格特征与消费者行为之间的关系，帮助企业制定精准的营销计划^[4]。同时，结合用户的语言模式推断其 MBTI 类型，优化推荐算法，分发个性化、个人化的内容。在心理健康领域^[5]，该系统可以根据文本中的情绪表达检测心理状态的变化，为风险

预警提供技术支持。

从公共利益角度来看，教育部门^[6]可以利用该系统识别学生认知风格的差异，并根据学生的能力优化教学策略；人力资源经理可以使用语言模式分析来促进人才评估和职位搜索。此外，该系统还可以通过精准的个人画像，提高社会服务的多样化水平，优化公共资源配置效率。

1.2 国内外研究现状

1.2.1 MBTI 与语言风格研究

早期研究主要集中在问卷调查和实验室观察的基础上，探讨 MBTI 人格类型与语言使用的关系。Pennebaker 和 King 的研究^[7]发现，个体的词汇选择与其人格特质存在显著相关性。并且其中的实验数据表明，语言风格是探索人格的一种独立且有意义的方式。随着计算语言学的发展，研究者开始使用自然语言处理技术分析大规模文本数据。Chang H. Lee^[8]等人在对韩语和性格之间联系的研究中发现性格特征与语言变量之间是显著相关的，并且还讨论了语言使用作为性格标志的作用。

Gjurković^[9]等人推出了 PANDORA，这是首个包含 1 万名用户评论的 Reddit 数据集，并对此进行了研究，他们分析了 Reddit 平台上的用户帖子，发现不同人格类型的用户在语言表达上确实存在差异。

国内研究方面，张岩峰^[10]等基于微博文本数据，分析了人格类型与语言表达的关联。他们根据用户发表的言论等来进行分类分析，提出了可以代表用户的不同行为和心里的各类特征，并且运用机器学习方法对其进行分类。纪雨^[11]在研究中提出了 POPD 模型，这是一个建模方法，基于不同的性格有不同的情感表达偏好。

从上述研究中可看出，这一领域的研究方法逐渐从问卷调查和观察发展到大规模文本数据分析，而且不同 MBTI 类型的人在语言表达上确实存在可识别的模式。张岩峰^[10]等人在中文语境下的研究进一步证实了这一现象的跨文化普遍性。这些发现让我意识到语言分析作为人格评估工具的巨大应用前景，它可能为心理健康监测、个性化服务和人际互动提供新的科学基础。

1.2.2 自然语言处理与深度学习技术

自然语言处理（Natural Language Processing, NLP）^[12]是结合计算机科学和语言学的交叉学科。其目标是利用算法实现对人类语言、内容生成和人机交互的智能分析。该学科基于理论框架，采用多种技术方法对语言数据进行自动分类和表征。在文本分析的早期研究阶段，研究人员主要使用手动特征提取和经典机器学习算法，例如贝叶斯分类器、SVM 模型和集成决策树。以 Tadesse 等人^[13]的研究为例，他们利用 XGBoost 分类器来预测 my Personality 数据库中的用户性格特征，最终模型的准确率达到 74.2%。尽管传统方法在计算速度和模型可解释性方面具有优势，但有效地对文本中的语义关联和长距离连接属性进行建模却具有挑战性。

随着人工智能技术的快速发展，深度学习方法在 NLP 领域取得了显著进步。其中，时间神经网络及其增强架构在处理数据时能力出色，包括带有记忆门机制的长短期记忆网络（Long Short-Term Memory, LSTM）和门控循环单元（Gated Recurrent Unit, GRU）。Tandera 等人^[14]于 2017 年将 LSTM 应用于基于 Facebook 帖子的 MBTI 预测，使用 MLP 和 LSTM+CNN 1D 架构，准确率最高为 93.33%。并且还发现了在深度学习实现中，每种架构的平均准确率差异很大，这可能是因为数据集或者用于预测的分类模型及其特征。UD Gandhi^[15]等人将 CNN 和 LSTM 模型应用于包含五万条电影评论的 IMDB 数据集，测试准确率分别为 87.74%和 88.02%。

注意力（Attention）机制的引入为深度学习模型带来了显著提升，展现出了优异的序列建模能力。尽管 LSTM 能够捕捉长期依赖关系，但是其在多个时间步长内对子窗口特征给予不同程度的关注的能力尚不足。针对这一问题，Y Li^[16]等人提出了一种基于进化注意力机制、具有竞争随机搜索能力的 LSTM 训练方法，用于多变量时间序列预测。与传统机器学习方法相比，深度学习模型能够自动学习复杂的非线性特征表示，更好地捕捉语言数据中的长距离依赖关系和上下文信息，从而有可能揭示更为细微的语言风格与人格特质之间的联系。B Zhang^[17]等人于 2023 年提出了一种注意力机制 PsyAttention 进行人格检测，在 MBTI 模型上达到了 86.30%的平均准确率，这超越了以往的方法，也证明了注意力机制的加入在心理特征编码方面是有效的。孙丽璐^[18]等人构建了一种融合多通道信息的 MCIPP，综合运用双向长短期记忆网络（Bidirectional Long Short-Term Memory, BiLSTM）、Attention、图卷积神经网络（Graph Convolutional Networks, GCN）等，最终达到了 0.806 的准确率。

自适应矩估计（Adaptive Moment Estimation, Adam）优化算法的核心是动态调整每个参数的学习率，利用梯度的一阶矩（均值）和二阶矩（方差）估计值，实现高效且稳定的模型训练。相较于采用固定学习率的随机梯度下降等传统方法，Adam 能够根据各参数的梯度变化趋势和历史信息进行自适应调整，从而在神经网络训练中提升收敛速度和稳定性。

综上，早期研究主要依赖人工特征工程和传统机器学习模型，而随着深度学习的兴起，神经网络逐渐成为主流方法，这大幅提升了人格预测的准确性和泛化能力。

1.3 研究目标与内容

1.3.1 研究的目标

本研究的总体目标是探索 MBTI 人格类型与个体语言风格之间的联系，并基于深度学习技术构建高准确率的自动化预测模型。

具体研究目标包括：分析大规模文本数据集中的语言特征与 MBTI 人格类型之间的统计关联，识别不同人格类型在词汇选择、句法结构和表达风格等方面的差异模式；设计并实现基于 LSTM、Bi-LSTM、Bi-LSTM+Attention、Bi-LSTM+Attention+Adam 的深度学习模型，并加入 k 折交叉验证；与传统机器学习方法进行对比，评估不同模型在 MBTI 人格预测任务上的性能，并且分析模型在 MBTI 不同维度的预测准度；开发一个基于最优模型的交互式前端系统，实现对用户输入文本的实时 MBTI 人格类型预测。

1.3.2 研究的主要内容

数据采集与预处理：获取 MBTI 数据集并进行清洗、分词、文本标准化等。

特征抽取与表征：运用词嵌入方法将语言材料转化为高维特征向量，捉语义关系的同时，也满足神经网络模型的输入要求。

模型设计与实现：构建 LSTM、Bi-LSTM、Bi-LSTM + Attention 和 Bi-LSTM + Attention + Adam 四种深度学习模型并加入 k 折交叉验证，同时实现 SVM、XGBoost、Logistic Regression、CatBoost、Gradient Boosting、Random Forest、Multinomial Naive Bayes 等 7 传统机器学习模型作为对比。

模型训练与评估：使用训练集对各模型进行训练，并在测试集上评估模型性能，采用准确率、精确率、召回率和 F1 值等指标进行多维度评价。

结果分析与讨论：分析不同模型的性能差异，研究不同 MBTI 维度的预测准确度。

交互式系统开发：基于最优模型设计并实现一个交互式前端系统，包括超文本标记语言（HyperText Markup Language, HTML）、层叠样式表（Cascading Style Sheets, CSS）和 JavaScript（JS）实现的用户界面以及 Python 后端处理逻辑，实现用户文本输入与 MBTI 人格类型预测的人机交互功能。

1.4 论文结构

本论文总共六个部分，详细安排如下：

第一章绪论，分析研究课题的背景和现实意义，梳理国内外研究现状，说明关键科学问题和研究目标，并阐述了论文的总体框架。

第二章理论基础，分析 MBTI 性格分类体系的理论基础，介绍自然语言处理和深度学习，为后续实验奠定理论基础。

第三章研究方法与实验设计，详细介绍数据收集渠道和预处理步骤、特征工程的处理方法、四个深度神经网络和七个经典机器学习模型，同时解释所使用的评估指标与实验环境。

第四章实验结果与分析，比较各模型的性能，在四个 MBTI 维度上分析预测效果的差异。

第五章人机交互系统设计与实现，说明交互式应用程序的设计流程，有前端设计和后端集成。

第六章结论与展望，总结本次论文，分析当前工作的不足之处，指出未来可能的改进方向。

除以上六个章节外，还包括参考文献、致谢等部分。

第二章 相关工作

2.1 MBTI 人格理论

2.1.1 MBTI 人格类型概述

20 世纪中期，布里格斯母女在荣格理论框架基础上，开发出迈尔斯-布里格斯类型指标（MBTI）^[19]这一包含 16 种性格类型的分类指标。该工具评估人们在四个关键心理维度上的自然倾向，用特定字母组合标识不同性格特征。

MBTI 的核心观点描述，人们在认知过程、信息接收、判断方式及行为习惯等方面有相对固定的偏向。这些偏向能反映个体最舒适的心理状态和行为模式，但并不代表能力高低或专业素养的体现。也就是说这些偏好只是代表心理特征差异，没有优劣之分。虽然目前对 MBTI 的科学性仍存在争议，特别在其理论假设、测量信效度等方面，但因其分类直观、操作便捷且具有实际指导意义，在教育咨询、职业规划、企业管理及团队建设等领域被广泛采用。

2.1.2 MBTI 四维度特征分析

MBTI 人格类型系统基于以下 4 个二分维度^[20]，每个维度代表两种相对的心理偏好。这四个维度共组合成 16 种性格类型，分别由四个字母定义，如 INTJ、ESFP 等。

（1）能量来源与方向（E/I）：外向（Extraversion, E）与内向（Introversion, I）

外向型（E）：倾向于从外部世界汲取能量。他们喜欢社交互动，善于口头表达，行动导向，兴趣广泛。

内向型（I）：主要从内心的精神世界汲取能量。他们需要独处来恢复精力，喜欢深入思考，三思而后行，并且更注重深入研究。

（2）信息获取方式（S/N）：感觉型（Sensing, S）与直觉型（iNtuition, N）

感觉型（S）：关注具体事实和细节，相信经验和实际观察，注重现实和当下，喜欢循序渐进。类似高清摄像机，捕捉当下环境的每一个细节。

直觉型（N）：关注模式和可能性，寻找意义和联系，关注未来和创新，喜欢跳跃式思考。如同望远镜，能看到远处的景象和潜在发展趋势。

（3）决策方式（T/F）：思考型（Thinking, T）与情感型（Feeling, F）

思考型（T）：基于逻辑和客观分析做决定，重视真相和公正，可能显得冷静或超然。如同计算机处理器，通过算法和逻辑运算得出结论。

情感型（F）：基于个人价值观和人际和谐做决定，考虑决策对人的影响，注重共识和认同。如同社交网络，重视连接点之间的关系质量和整体和谐。

（4）生活方式（J/P）：判断型（Judging, J）与感知型（Perceiving, P）

判断型（J）：喜欢计划和组织，寻求封闭和决议，遵循时间表，注重结果和完成。如同铁路系统，按照预定路线和时刻表运行。

感知型（P）：灵活自发，保持选项开放，适应变化，享受过程和探索。如同探险船，可以根据发现的新信息随时调整航向。

2.1.3 MBTI 与语言行为的关联研究

MBTI 人格特质与语言表达模式之间存在显著关联^[7]，这为心理语言学提供了新的研究视角。研究^[21]表明，不同类型的人格在词汇偏好、句法特征、说话风格和话题选择等方面存在差异。

能量维度（E/I）与语言特征：外向者（E）的表达方式生动活泼，其语言具有一定的社会交往特征，多使用第一人称复数和第二人称代词，句式简洁清晰，情绪色彩积极鲜明，内容更侧重于群体行动或具体行为。相比之下，内向者（I）的语言风格更具思考性，句式结构更加复杂多样，词汇选择更具针对性，抽象性更强。

信息维度（S/N）与语言特征：感觉型（S）个体的语言表达呈现出一些特定特征。他们的文本通常包含细致的描述和情感词汇，以现在时和过去时态作为关键时刻。而直觉型（N）个体则展现出截然不同的语言模式，更倾向于抽象概念和理论性讨论，善于运用隐喻等修辞手法，富有创造力和前瞻性。

决策维度（T/F）与语言特征：T 型个体的语言特点是逻辑性强，使用更多因果连接词（“因为”“所以”），情感词汇较少，表达客观分析和批判性思考，词汇精确而具体。F 型个体使用更多情感词汇和评价性词汇，表达共鸣和同情，句子中出现更多表示个人观点的短语（“我认为”“我感觉”），以及表示人际关系的词汇。

生活方式维度（J/P）与语言特征：J 型个体的语言表现出结构化和确定性，使用更多表示确定和决断的词汇，时间词汇频繁出现，语言简洁明确。P 型个体的语言更为开放和探索性，使用更多表示可能性的词汇（“也许”“可能”），句子结构较为灵活，常使用未完成时态和开放式表达。

2.2 自然语言处理技术

2.2.1 文本表示方法

文本表示是自然语言处理的基础步骤，旨在将非结构化的文本数据转化为计算机可处理的数值形式。

(1) 词袋模型(Bag of Words, BoW)^[22]

词袋模型是最基本的文本表示方法，它将文本视为无序词汇的集合，忽略语法和词序，只关注词汇是否出现以及出现的频率。每个文档被表示为一个词汇表大小的向量，向量中的每个元素对应词汇表中某个词的出现次数或频率。

词袋模型简单直观，计算效率高，实现容易，但存在维度灾难(生成高维稀疏向量，计算效率低下)、语义信息丢失(忽略词序和上下文关系)、无法处理同义词和多义词(例如“好”和“良好”被视为完全不同的特征)以及无法捕捉词的语义相似性(如“苹果”和“梨”这类语义相近的概念)等缺点。

(2) 词频-逆文档频率(Term Frequency-Inverse Document Frequency, TF-IDF)^[23]

TF-IDF 是对词袋模型的改进，引入了 IDF。它不仅考虑词频，而且能降低常见词的权重，提升稀有词的重要程度。可将 TF-IDF 比作图书检索系统，如果搜索“人工智能”，那么在一本书中“人工智能”出现的次数越多（高 TF 值），这本书越可能与搜索相关，但如果“人工智能”一词在图书馆的大多数书中都出现（低 IDF 值），那么这个词的区分能力就不强。而“深度学习”这样在较少书中出现的专业词汇（高 IDF 值）可能更具有识别力。

TF-IDF 的计算公式为：

$$TF-IDF(t, d, D) = TF(t, d) \times IDF(t, D) \quad \text{公式 2.1}$$

其中， $TF(t, d)$ 为词 t 在文档 d 中的频率， $IDF(t, D)$ 为词 t 的逆文档频率，通常计算为：

$$IDF(t, D) = \log(N/DF(t)) \quad \text{公式 2.2}$$

N 为语料库中的文档总数， $DF(t)$ 为包含词 t 的文档数量。

TF-IDF 模型相比纯词频能更好地反映词对文档的重要性，特别适用于文档检索和关键词提取，但仍没有解决词序和语义的问题。此外，它也无法处理出现频率很低但语义重要的词，以及完全没出现过的词（零频率问题）。

(3) N-gram 模型^[24]

为了部分保留文本的顺序信息，N-gram 模型将连续出现的 N 个词作为一个特征单元。常见的有二元语法(Bigram)和三元语法(Trigram)。

N-gram 模型可以类比为记忆短语而不仅仅是单词。比如，在分析“北京是中国的首都”这句话时，不仅记录“北京”“是”“中国”等单词，还会记录“北京是”“是中国”“中国的”这样的短语组合。因此 N-gram 能够捕捉局部的词序依赖关系，保留部分上下文信息。但随着 N 的增加，特征空间呈指数级增长，导致数据稀疏问题更加严重，并且仍然无法捕捉长距离依赖关系。对于未见过的 N-gram 组合无法给出准确估计（数据稀疏问题），而且 N 较大时存储开销大。

不同 N 值的应用场景：

N=1：适用于简单的文本分类

N=2：常用于拼写检查、简单的语言模型

N=3：用于更复杂的语言建模、机器翻译

较大的 N 值：在特定领域应用，如 DNA 序列分析

(4) 词嵌入(Word Embedding)

词嵌入技术将词映射到低维稠密向量空间，使语义相近的词在向量空间中距离相近。这种表示方法不仅大幅降低了维度，还能捕捉词之间的语义关系。词嵌入可以类比为给每个词分配一个多维坐标，使得语义相似的词在这个空间中彼此接近。就像在一个城市地图上，相似功能的建筑（如餐厅）往往距离相近，而不同功能的建筑（如餐厅和医院）则距离较远。主流的词嵌入技术有 Word2Vec、GloVe 和 FastText 等，会于下一节详细介绍。

词嵌入技术能进行降维（从高维稀疏表示转变为低维稠密表示，通常 100-300 维），迁移学习（预训练的词向量可应用于多种下游任务），还能捕捉语义信息（词之间的语义相似度和类比关系），提升泛化能力（能处理训练中未见过的词，尤其是 FastText）等。但也存在静态表示的问题，即同一个词在不同上下文中的表示相同，无法处理一词多义。还缺乏句法和篇章级别的语义理解，需要大量语料库才能学习高质量的词向量。

(5) 预训练语言模型表示

基于 Transformer 架构的预训练语言模型如双向编码器表征(Bidirectional Encoder

Representations from Transformers,BERT)、生成式预训练转换器(Generative Pre-trained Transformer,GPT)等带来了文本表示的进步。这些模型通过自监督学习在大规模语料上预训练,获得了丰富的语言知识,能够生成上下文感知的动态词表示,更好地捕捉词在特定上下文中的语义。

Google 于 2018 年提出了 BERT^[25],其采用双向 Transformer 架构,通过掩码语言模型(Masked Language Model,MLM)和下一句预测(Next Sentence Prediction,NSP)两个预训练任务学习文本表示。BERT 的双向上下文编码能够同时考虑词的左右上下文信息,并且其生成的是动态、上下文感知的词表示,这解决了一词多义问题。

GPT 由 OpenAI 开发,采用自回归语言模型进行预训练,通过预测下一个词来学习文本表示。与 BERT 不同,GPT 是单向的(只考虑左侧上下文),但在生成任务上表现出色。

预训练语言模型有许多优点,能够根据上下文动态调整词的表示,可以捕捉句法结构和深层语义关系。还具有较强的迁移能力,可通过微调适应各种下游任务。能进行少样本学习,在数据有限的情况下也能取得良好效果。

2.2.2 词嵌入技术

词嵌入是当代自然语言处理的基础技术之一,通过将词汇映射到连续向量空间,使计算机能够理解和处理词汇之间的语义关系。与传统的独热编码相比,词嵌入生成的低维稠密向量能够更有效地捕捉词汇的语义特征。就像我们可以把每个词想象成一个多维空间中的点,语义相近的词在这个空间中距离较近,如同同类物品在超市中通常摆放在相邻的货架上。以下介绍几种主流的词嵌入技术:

(1) Word2Vec^[26]

Word2Vec 是由 Google 团队于 2013 年提出的词嵌入方法,包括两种架构,使用上下文词预测目标词的连续词袋模型(continuous bag of words, CBOW)和使用目标词预测上下文词的跳字模型(Skip-gram)。

Word2Vec 基于分布式假设,即“相似的词出现在相似的上下文中”,通过浅层神经网络学习词向量。训练完成后,语义相近的词在向量空间中距离较近,且词向量间的关系可以表达语义关系,如“king - man + woman $\approx$ queen”这样的类比关系。生成的词向量通常为 50-300 维,这有效降低了维度灾难问题,同时保留了丰富的语义信息。

(2) Global Vectors for Word Representation (GloVe) [27]

GloVe 由 Stanford 团队开发,结合了全局矩阵分解和局部上下文窗口方法的优点。它直接对词共现统计矩阵进行建模,目标函数设计使词向量的内积与词共现概率的对数成正比。

GloVe 的训练目标是:

$$J = \sum(i,j) f(X_{ij})(w_i \cdot w_j + b_i + b_j - \log X_{ij})^2 \quad \text{公式 2.3}$$

其中 X_{ij} 是词 i 和 j 的共现次数, $f(X)$ 是权重函数, w_i 和 w_j 是词向量, b_i 和 b_j 是偏置项。

与 Word2Vec 相比, GloVe 更好地利用了全局统计信息,在处理复杂语义关系时,于某些语义任务上表现更优。如果说 Word2Vec 是通过局部观察来理解词义关系,那么 GloVe 则像是一名同时掌握全局统计和局部模式的专家,既能看到森林全貌,又能辨识每棵树的特点。

(3) FastText^[28]

FastText 是 Facebook 研究院开发的词嵌入技术,它将词表示为字符 n-gram 的集合,而不是将每个词视为最小单位。例如,对于词“where”,使用 $n=3$ 的情况下, FastText 会生成“<wh>”, “<whe>”, “<her>”, “<ere>”, “<re>”等子词,并学习这些子词的向量表示。最终词向量是所有子词向量的总和。

该技术能够处理词汇表外的词,为罕见词生成高质量向量,而且形态丰富的语言效果好,能捕捉词缀信息,对拼写错误有更强的鲁棒性。这就像一个精通音标的学习者,即使遇到从未见过的单词,也能通过分析其构成部分来推测其发音和含义。

(4) 上下文化词嵌入

传统的词语表征方法使用固定向量来表征词语,无法适应不同语境下的语义变化,这在处理多义词时尤为明显。为克服这些问题便出现了上下文化词嵌入技术,如 ELMo (Embeddings from Language Models) 和 BERT。

ELMo 模型基于双向长期记忆网络,其预训练大量文本数据,能根据特定语境生成灵活的词向量。这种动态表征方法类似于人类的认知处理,能够根据社会语境动态地解读他人的言语。BERT^[25]模型采用 Transformer 框架,利用掩码语言模型学习策略,实现更深层次的语境表征,它利用二进制编码机制融合语境信息,获得更精准的语义理解。

这种技术能够有效捕捉语言复杂的语义关系和语法特征，并在各个空间理解层面展现出优秀的性能提升和迁移学习能力。

2.2.3 文本特征提取

文本特征提取是从原始文本中识别和提取能够代表文本内容和风格的特征，为后续机器学习或深度学习模型提供输入。在 MBTI 人格与语言风格关联研究中，有效的特征提取对模型性能至关重要。并且有研究表明^[29]，语言特征与 MBTI 维度存在相关性。

（1）统计特征

统计特征就像给一段文字做体检，关注文本的表面特性，例如整篇文字包含多少字符、单词和句子，每句话、单词的平均长度，以及逗号、句号、问号等标点符号出现的频率和分布，还包括大写字母与小写字母的比例，以及诸如@、#、&之类特殊符号的使用情况。通过这些基本测量数据，可以快速了解不同写作风格的特点。这些统计特征看似简单，但在文本分类或识别任务中，尤其是结合其他特征一起使用时，能发挥很好的效果。

（2）词汇特征

作为文本的“语言标识符”，词汇特征可以有效地描述词语的使用模式和作者的沟通风格。根据具体的分析层次，词频分布可以反映特定词语的使用强度，TF-IDF 值可以评估一组文档中词语的可区分性。本研究还关注特定名词（如人名、地名）、抽象词（如“理念”“价值”）和情感词汇（例如“抑郁”“愉悦”）的分布，这些词汇能够捕捉理解文本主要内容和情感基调。

在定量评估方面，重要的标准是语言表征的丰富性和复杂性，可以通过词汇多样性指标（例如类型-标记比）和词汇复杂度指标（例如长词密度或平均词长）来衡量。为了高效地提取这些词汇特征，常用的处理方法有用词袋模型或 N-gram 模型，为文本特征的量化分析提供了可靠的技术支持。

（3）语法特征

对句子结构、语法类别分布等语法特征进行定量分析，有助于揭示人们的语言策略和文本的风格特征。例如，统计名词、动词、副词等语法类别的数量，有助于理解文本内容的组织，而句法依存树的深度、句子数量等结构复杂性指标，则反映了句子内部的层级关系和嵌入结构的丰富程度。

此外，时态、语频（例如主动语态与被动语态的比例）、第一人称代词的使用频率等特征，也反映着文本对客观描述和主观表述的重视。就像为了保证科学客观的表述，学术文章通常倾向于使用被动语态和第三人称，而叙事性文本则倾向于使用主动语态和第一人称，以增强读者的参与度和共鸣。

前面提到的语法信息抽取，是基于词性标注（POS tagging）、句法分析（syntactic parsing）等自然语言处理技术。借助 SpaCy、Stanford NLP 等工具可以系统地计算句法层面的诸多特征，提升文本分类、风格识别、作者识别等任务的性能和准确率。

（4）语义特征

语义分析旨在解析文本隐含的概念关联与情感内涵，关键是对语言的内在逻辑进行量化表征。以主题建模方法为例，潜在狄利克雷分布（LDA）和潜在语义分析（LSA）等技术能识别文档在不同主题中的分布特征，使文本内容架构能够理解。情绪分析意为模型评估文本所传递的情感极性及其强度，认知复杂度指标可衡量信息呈现的逻辑性与系统性。

在词汇表征方面，基于神经网络的嵌入技术（如 Word2Vec、GloVe 及 BERT）能够学习词语在上下文中的分布式特征，反映词汇间的语义相似性。与传统的词频统计或语法解析不同，这类方法更注重挖掘语言背后的概念关联模式。因此，语义特征在文档归类、内容主题挖掘以及情感计算等任务中具有显著优势。

通常，语义特征的建模需要结合概率图模型或深度学习方法，并依托大规模文本数据进行参数优化，以此来提高特征表达的鲁棒性和预测准确性。

（5）深度学习

特征随着深度学习的发展，基于神经网络的自动特征提取方法日益流行。比如卷积神经网络提取的局部特征图（特征这些方法不需要人工设计特征，而是让模型自动学习对任务有用的表示）通常能捕捉到更复杂和隐晦的模式。深度学习特征就像是文本的“神经表征”，通过多层次的和抽象来捕捉文本的本质特征。例如，BERT 等预训练模型可以生成上下文敏感的词嵌入，能够区分多义词在不同语境下的意义。变压器架构的自注意力机制则能够捕获长距离依赖关系，这在传统方法中很难实现。

（6）心理语言学特征

心理学特征类似于文本的“心理画像”，能够揭示作者的心理状态、认知过程和社会关系。例如，高频使用不确定性词汇可能表明作者的焦虑或情感倾向，而因果词

的大量使用则可能反应分析思维。具体的有语言意识单词计数，认知过程标记（认知、洞察、因果等），社会过程标记（亲属、朋友、人类等），心理状态词汇（情感、感知、欲望等）等。

2.3 深度学习理论与方法

2.3.1 循环神经网络（Recurrent Neural Network, RNN）基础

RNN^[30]是一类专门处理序列数据的神经网络结构，非常适合自然语言处理、语音识别、时间序列预测等时序数据分析任务。与传统前馈神经网络只能处理固定长度输入并且各输入之间相互独立不同，RNN 引入了内部状态（hidden state）的概念，使网络具有“记忆”能力，能够保存历史信息并利用之前的信息来影响当前的输出。

（1）RNN 的基本结构

RNN 的核心思想是在网络中引入循环连接，使信息可以从前一时间步传递到当前时间步，从而形成信息的时序传递。最简单的 RNN 由一个循环单元（recurrent unit）组成，在每个时间步接收两个输入：当前时间步的输入 x_t 和前一时间步的隐藏状态 h_{t-1} ，然后计算当前时间步的隐藏状态 h_t 和输出 y_t 。这种结构可以看作是同一神经网络在时间维度上的多次复制，且相邻副本之间存在连接。

基本 RNN 单元的计算过程如下：

$$\begin{aligned} h_t &= \tanh(W_{hx}x_t + W_{hh}h_{t-1} + b_h) \\ y_t &= \text{softmax}(W_{yh}h_t + b_y) \end{aligned} \quad \text{公式 2.4}$$

其中： h_t 是 t 时刻的隐藏状态，可视为网络的“记忆”； x_t 是 t 时刻的输入； y_t 是 t 时刻的输出； W_{hx} 是输入到隐藏层的权重矩阵； W_{hh} 是隐藏层到隐藏层的权重矩阵，控制历史信息的保留程度； W_{yh} 是隐藏层到输出层的权重矩阵； b_h 和 b_y 是偏置向量； $\tanh$ 和 softmax 是激活函数，其中 $\tanh$ 函数将隐藏状态值压缩在 $[-1,1]$ 区间，而 softmax 函数则将输出转化为概率分布。RNN 在所有时间步上共享这些权重参数。

（2）RNN 的前向传播和反向传播

在前向传播过程中，RNN 按时间顺序依次计算每个时间步的隐藏状态和输出。即网络首先初始化隐藏状态 h_0 （通常设为零向量），然后从 $t=1$ 开始，依次计算每个时间步的隐藏状态 h_t 和输出 y_t ，直到处理完整个序列。

反向传播采用“通过时间的反向传播”(Backpropagation Through Time, BPTT)^[31]算

法，将误差沿时间方向逆向传播。与标准反向传播不同，BPTT 需要考虑误差如何通过时间步传递。BPTT 的核心思想是将 RNN 展开为等价的前馈网络，然后应用标准的反向传播算法。误差从最后一个时间步开始，逐步向前传播到第一个时间步。总误差是各时间步误差的累积。在实际应用中，由于计算和内存限制，常采用截断 BPTT，即只将误差向前传播固定的时间步数而非传播到序列起始。

（3）RNN 的优势和局限

RNN 有许多优点，其一就是能处理不同长度的序列数据，这让 RNN 可以轻松应对不同程度的输入和输出条件。不仅如此，它的参数划分策略在一定程度上减少了模型参数的数量，有助于提高计算效率，还可以缓解过拟合问题。RNN 在时间序列建模、序列生成和预测等场景广泛应用。

但是传统 RNN 结构存在梯度消失和梯度爆炸问题，即在处理较长的序列时，误差梯度可能会很快降至接近零，或者相反，呈指数级增长，这会严重削弱模型学习长程依赖关系的能力。不仅如此，RNN 的学习过程复杂，经常收敛缓慢并陷入局部最优。标准 RNN 结构采用单向传播方式，仅依赖于当前和先前时间步的信息，忽略未来时刻的数据，这限制了其在某些任务中的性能。

为了解决上述问题，研究人员提出了各种改进的 RNN 结构^[32]，比如长短期记忆 (LSTM) 网络和门控循环单元 (GRU)。这些变体能在保持长期序列处理重要性的同时，保持更鲁棒的长期连接建模能力，提升整体性能。

2.3.2 LSTM 与变种模型

LSTM^[30]是对 RNN 模型的一种改进，引入门控机制和记忆单元，能有选择地存储和访问长序列信息，专门设计用来解决原始 RNN 难以学习长距离依赖关系的问题，提高了处理长文本的能力。

（1）LSTM 的基本结构

LSTM 的核心是一个记忆单元(cell)，包含一个单元状态(cell state)和三个门控单元，这三个门控单元分别为输入门(input gate)、遗忘门(forget gate)和输出门(output gate)，它们控制信息的流入、存储和流出。

（2）Bi-LSTM

标准 LSTM 只能获取序列中前面的信息，而在许多 NLP 任务中，一个词的含义往往依赖于它前后的上下文。Bi-LSTM 通过同时从前向和后向处理序列，能够捕捉

双向上下文信息。

Bi-LSTM 包含两个独立的 LSTM 层：前向 LSTM 层从左到右处理序列，后向 LSTM 层从右到左处理序列。最终，每个时间步的表示是两个方向 LSTM 输出的拼接或融合：

$$h_t = [h_t^{forward}; h_t^{backward}] \quad \text{公式 2.5}$$

这种双向信息流使其能够更全面地理解文本语义，适合需要考虑完整上下文的任务，如词义消歧、情感分析和文本分类。Farah Shahid^[33]等人利用 Bi-LSTM 在中国康复病例中建立模型预测，获得了优秀的 $r2_{score}$ 值，为 0.9997。

(3) LSTM+Attention

与传统的对整个序列进行均匀编码的方法不同，Attention 机制帮助模型在分析序列数据时持续关注序列中高度相关的部分，该机制是深度学习领域的一项重大创新，在序列建模任务中具有显著优势。

处理时先使用 LSTM 层对输入序列进行编码，并输出与每一步对应的隐藏状态 h_t ，然后计算每个隐藏状态的注意力分数 α_t ，加权平均所有隐藏状态得到上下文向量 c ，将上下文向量用于生成最终输出。

$$\begin{aligned} \alpha_t &= \text{softmax}(\text{score}(h_t, \text{context})) \\ c &= \sum \alpha_t \cdot h_t \end{aligned} \quad \text{公式 2.6}$$

注意力机制使模型能够识别并关注对预测任务最重要的单词或短语，有效提高模型性能。并且 Y Li^[34]等人研究发现与其它基准方法相比，增加 Attention 的 LSTM 模型能够取得有竞争力的预测性能。

(4) 具有自适应学习率的 LSTM 模型

深度学习模型的训练效果受到学习率的影响，传统方法采用固定学习率或预定义分解模式，但这些静态调优方法难以满足不同网络参数和训练阶段的动态优化需求。为此自适应学习率优化方法应运而生，Adam 算法是其中的典型代表。该算法在参数层面进行自适应学习率调整，同时保留每个参数的历史梯度统计信息，包括一阶矩估计值（动量）和二阶矩估计值（方差）。

2.3.3 注意力机制原理

注意力机制是一种神经网络的组成部分，其设计灵感来源于人类认知中的选择性注意现象。当面对大量信息时，人脑能够有意识地聚焦于相关内容，并忽略不重要

的部分，以此提升信息处理的效率。深度学习模型中的注意力机制旨在模仿这一过程，使得模型能够动态地“关注”输入序列中的关键部分。

（1）注意力机制的基本原理

注意力机制的主要思想是根据注意力权重对输入序列的各部分基于不同程度的关注。对输入序列的每个部分进行计算得到注意力分数，这样能确定该单元对当前任务的重要性，然后用归一化函数（例如 `softmax`）进行处理，确保它们符合概率分布的特征，就能用得到的权重系数用于加权平均来获得上下文向量。

用更加直观的数学方式来描述上述的计算过程就是对给定的当前状态 s 和输入序列 $(x_1, x_2, \dots, x_n)$ ，在 x_i 上计算注意力分数：

$$e_i = f(s, x_i) \quad \text{公式 2.7}$$

其中 f 是评分函数，再用 `softmax` 函数归一化得到注意力权重 α_i ，对其计算加权和得到上下文向量 c 。

（2）注意力机制的类型^[35]

Bahdanau 注意力（加性注意力）：由 Bahdanau 等人提出，用前馈神经网络来生成注意力分数。这种机制在序列转换模型中非常有用，例如语言间的机器翻译。

Luong 注意力（乘性注意力）：用不同的相似度度量方法（点积、通用和拼接）算注意力得分。相较而言，这种方法在计算效率方面表现更佳，适合处理大规模序列数据。

Hierarchical Attention（层次注意力）：采用多级注意力模型实现文本建模，典型架构包含词级和句子级两个处理层级。是先词典级别创建句子表征，然后在句子级别泛化文档表征。这种分层处理策略可以有效地建模文本的分层语义特征，更能捕捉到文本结构信息。

Multi-Head Attention（多头注意力）：将注意力机制分解为多个“头”，每个头独立学习不同的表示子空间，然后将结果拼接，能够同时关注不同位置 and 不同表示子空间的信息。

Self-Attention（自注意力）：自注意力不依赖外部状态，而是通过序列内部元素之间的关系计算注意力。它将序列中的每个元素与同一序列中的所有元素进行注意力计算，这样能捕捉序列内部的依赖关系。

（3）注意力机制在文本分类中的应用

引入注意力机制使得模型更关注关键词，可以自动识别与分类目标相关的关键词，提高特征提取的针对性。可处理长距离依赖，克服传统 RNN 模型在处理长文本时的梯度消失问题，使模型能够关注序列中任意位置的相关信息。也能提高可解释性，注意力权重的可视化展示了模型关注的文本部分，使预测结果更具可解释性。通过自动选择最相关的特征，注意力机制能显著提高文本分类的准确率，尤其是在数据集较小或类别特征不明显的情況下。就像 DP Tuan^[36] 等人用了 3 种注意力机制模型在小数据集上进行评估，发现在他们的研究中 Bahdanau 模型表现最好。

2.3.4 自适应学习率算法

学习率是深度神经网络优化过程中的关键超参数，影响训练模型的收敛性和泛化能力。和静态学习率策略相比，动态自适应学习率方法实时调整参数更新步长，大幅提升了复杂优化场景下的训练效果。该类算法根据梯度统计或训练状态自动调整学习率，不仅加速收敛过程，还能帮助模型获得更佳的性能。

（1）学习率的重要性与挑战

学习率可控制参数更新的步长，过大可能导致震荡或发散，而过小又会导致收敛缓慢或陷入局部最小值。理想的学习率应随着训练进行适当减小，保证收敛，能够根据参数重要性和梯度特性自适应调整，能够适应不同参数的不同更新需求，并且对训练数据分布变化具有鲁棒性，在训练早期能够快速探索参数空间，后期能对参数进行正确调整。

（2）自适应学习率算法举例^[37]

① Adaptive Gradient Algorithm (AdaGrad)

AdaGrad 算法是根据参数历史梯度的累积平方和来自适应地调整每个参数的学习率。同时记录每个参数的历史梯度平方和，并用这个累积值来调整学习率。对于经常更新的参数，累积和增长较快，导致学习率较小；对于不常更新的参数，累积和增长较慢，保持相对较大的学习率。

该算法可适应稀疏特征，能为不常更新的参数使用更大学习率，并且无需手动调整学习率，对每个参数自适应调整学习率，更符合不同参数的更新需求。但存在学习率会单调递减，后期可能过小导致训练停滞，且对于深度学习中的非凸问题，可能过早停止学习等问题。

② Root Mean Square Propagation (RMSprop)

RMSprop 算法引入了指数加权移动平均，这解决了 AdaGrad 学习率递减过快的问題，可维持适当的更新步长。该算法不再简单累加历史梯度平方，而是使用指数加权移动平均，赋予近期梯度更大的权重，远期梯度的影响会逐渐衰减。这样避免了累积和无限增长导致的学习率过小问题。但仍可能在梯度方向变化大的情况下表现不佳，由于不包含动量机制可能在某些问题上收敛较慢等问题。

③ Adaptive Moment Estimation (Adam)

Adam 结合了动量法和 RMSprop 的优点，同时计算梯度的一阶矩估计（均值）和二阶矩估计（中心化的方差）。Adam 在 RMSprop 的基础上增加了动量概念，不仅考虑梯度的二阶矩（方差），还考虑一阶矩（均值）。它维护两个移动平均值：一个是梯度的移动平均，相当于动量；另一个是梯度平方的移动平均，用于自适应调整学习率。还引入了偏差修正，解决了初始化阶段估计不准确的问题。

该算法能结合动量和自适应学习率的优势，参数更新的方向更稳定，并且对初始学习率不敏感，更易于调优；适用于大多数非凸优化问题；计算效率高，内存需求小；还解决了 RMSprop 中梯度更新方向不稳定的问题。但在某些情况下可能收敛到次优解，而且需要调整 β_1 、 β_2 等超参数的问题等。

第三章 研究方法设计

3.1 数据集构建与预处理

3.1.1 数据来源与介绍

(1) 本研究所使用的 MBTI 数据集名为“(MBTI) 迈尔斯-布里格斯性格类型数据集”，来自于公共平台，在 kaggle、天池等平台上均能找到。

(2) 数据集规模

数据集包含 8,675 条记录（行），每行代表一个人，索引范围从 0 到 8674，数据集完整，没有缺失值。共两列（type 和 posts），数据类型都 object。type 列代表此人的 4 个字母 MBTI 代码/类型，posts 列为他们最近发布的 50 件事的其中一部分（每个条目以 3 个竖线字符“|||”分隔）。数据集在内存中占用约 135.7+ KB 的空间。

(3) 数据集类别、维度分布

数据集中 16 种 MBTI 类型的分布如图 3.1 所示：




图 3.1 MBTI 类型分布

可看出，数据集中的 MBTI 类型分布非常不均衡，存在明显的偏向性。其中 INFP 是最常见的类型，有 1832 人，占总体的 21.1%，约五分之一的样本属于这一类型。前四种类型（INFP、INFJ、INTP、INTJ）占据了数据集的主要部分，它们分别占 21.1%、16.9%、15.0%和 12.6%，合计高达 65.6%，占据数据集的三分之二。最少见的四种类型是 ESTJ（39 人，0.4%）、ESFJ（42 人，0.5%）、ESFP（48 人，0.6%）和 ESTP（89 人，1.0%）。

数据分布呈现明显的长尾效应，前几种类型与后几种类型的数量差异非常大，最多的 INFP（1832 人）与最少的 ESTJ（39 人）相差约 47 倍。I 和 N 特质在数据集中明显占主导地位，特别是前四位全部以 IN 开头。相比之下，S 和 E 类型的表示较少，

尤其是 ES 组合的类型（如 ESTP、ESFP、ESFJ、ESTJ）在分布尾部，都不足 1%。

这种分布特征表明，数据集中 IN 类型的人群显著过度代表。这种不均衡的分布对模型的训练可能会造成偏差，所以在建模前需要先平衡样本。

再根据图 3.2 具体观察该数据集在 4 个维度上的分布：




图 3.2 MBTI 四个维度占比

① I/E 维度：I 型占绝大多数，有 6676 人，占比 77.0%；E 型仅有 1999 人，占比 23.0%。数据集中内向性格类型的表示明显过高。

② N/S 维度：分布最不均衡的一个，N 型高度主导，有 7478 人，占比 86.2%；S 型只有 1197 人，占比 13.8%。

③ T/F 维度：分布最均衡的一个，F 型略占优势，有 4694 人，占比 54.1%；T 型有 3981 人，占比 45.9%。

④ J/P 维度：P 型占多数，有 5241 人，占比 60.4%；J 型有 3434 人，占比 39.6%。两者差距明显但不如 I/E 和 N/S 维度那么极端。

（4）帖子总和长度分布

使用箱线图 3.3 来分析 16 种 MBTI 人格类型帖子总和长度的分布情况。从整体来看，大多数人格类型的帖子长度的中位数大约在 1000-1300 字之间，表明不同人格类型在文本长度上有一定的相似性，但仍然存在明显的差异。所有类型都有极端值，

表示有些帖子特别短，少于 500 字甚至更少。这些可能是简短回复或不完整的帖子。




图 3.3 帖子总和长度箱线图

具有 J 特质的人格类型（如 ENFJ、ESFJ、INFJ 等，中位数接近 1300-1400 字）似乎倾向于写较长的文章，而具有 P 特质的人格类型（如 ISFP、ESTP 等，中位数大约在 1000-1100 字左右）倾向于写较短的文章。但是，E 型和 I 型人格在文本长度上并没有显示出一致的明显差异。可以得出结论，MBTI 人格类型与个人表达方式长度之间存在一定的关联，特别是 J 型和 P 型的差异较为明显。

（5）帖子平均字数及其方差

ESFJ 和 INFJ 是平均字数最高的两种类型，平均每篇文章约 27-28 个词。这两种类型都带有 FJ 特征，所以 F 型与 J 型的组合可能倾向于更详细表达。相比之下，ISFP 的平均字数最低，约为 23 个词，这与前面分析的帖子总和长度结果相符，进一步支持了 ISFP 类型倾向简洁表达的特点。

整体看，所有类型的平均字数都在 23-28 个词之间，差异不算特别显著，说明无论哪种人格类型，在基本表达上的字数选择相对稳定。但 J 型人格整体上似乎比 P 型使用更多词汇。

接下来介绍方差分析的结果。ESFJ 类型有最低的方差（约 120），这类型的人在字数使用上较为一致，变化不大。而 ISFP、ESTP 等类型显示出较高的方差（约 140-150），这些类型的人在字数使用上差异较大。可以得出结论，FJ 类型（尤其是 ESFJ 和 INFJ）倾向于使用更多的词汇进行表达；P 型人格整体上使用词汇较少，但内部差异大；J 型人格整体上使用词汇较多，且较为一致；I 与 E 的差异在字数上不如 J 与 P 的差异明显。

（6）符号使用频率

对比 16 种 MBTI 人格类型在交流中使用问号(?)和感叹号(!)的平均频率，如图 3.4 所示。




图 3.4 各 MBTI 类型平均问号和感叹号使用量对比

可知，ESTP 类型平均使用问号最多，达到 12.3 次，是问号使用的“冠军”，反映了他们探索性和好奇心强的特质。ESFJ 类型使用问号最少，仅 8.8 次；大多数类型的问号使用频率在 10-11 次之间。ENFP 类型使用感叹号最多，高达 16.9 次，是感叹号使用的“冠军”；ISTP 类型使用感叹号最少，仅 4.6 次。

E 型和 I 型人格在书面表达方面存在差异，可以看到 E 型人格（例如 ENFP 和 ENFJ）在文本中更多地使用感叹号，这一语言特征与其情感型和社交型人格特征相符。相比 I 型人格（例如 ISTP 和 INTP）则表现出更为克制的标点符号使用习惯，其书面表达也趋于克制和谨慎。

进一步发现，T 型人格和 F 型人格的写作风格也存在差异。前者倾向于用更客观、简洁的表达，感叹号在文本中的使用频率通常较低，后者更注重情感传递，因此在书面交流中更频繁地使用标点符号和强调语气。

上述符号的分析结果与 MBTI 人格维度存在一定的相关性，并可能在一定程度上反映个体的心理特征和沟通风格。

（5）词云图

为了更好地了解和区别各人格的沟通风格，进一步构建词云图，通过视觉化的方式展示不同 MBTI 人格类型的语言使用模式，从中可以直观地反映各类型的沟通特征和思维倾向。

（1）文本清洗

首先，代码识别并删除所有网址链接。URL 通常不包含任何关于作者个性或写作风格的信息，在分析 MBTI 人格类型与语言使用的关系时，URL 只会增加无关的噪音。例如，“I see this video today [www.youtube.com /watch?v=12345](http://www.youtube.com/watch?v=12345), and I think it is funny”这句话中，网址部分对分析个人表达方式没有帮助。所以使用正则表达式模式匹配并删除所有以“http”开头后跟非空白字符的 URL 链接。

接下来，代码只保留英文字母和几个基本标点符号（逗号、句号、感叹号、问号），使用字符类否定和范围匹配将所有其他字符（如数字、特殊符号、表情符号等）替换为空格。这种处理确保了分析重点放在文本的语言内容上，而不是受到数字或特殊符号的干扰。

（2）深度文本预处理

起初，为保证词频分析的精确度，将全部文本内容统一转化为小写字母形式。此举有助于规避因字母大小写不同而引起的词汇重复计数问题。例如，“Think”、“think”和“THINK”经过此处理后将被视为同一词项。完成大小写统一化之后，下一步是对文本实施切分处理，利用自然语言处理工具（例如 `word_tokenize`）将连贯的语句拆分为若干独立的词语单位。比如，对于语句“I like reading books”，此过程会将其转化为一个由单词构成的列表 [“I”, “like”, “reading”, “books”]，为后续的词频属性分析奠定基础。

继初步分词之后，需要对获得的词语进行甄别，仅保留完全由英文字母组成的词项，包含数字、符号或标点符号的混合型词语（如同“covid-19”或“2023 年”）将会被排除在外。鉴于此类词汇通常与文本的表达风格关联性较弱，且其出现频率可能随时间推移而变化较大，因此保留它们对于研究目标的意义不大。

紧接着，需要进行停用词的剔除工作。在英语文本中，普遍存在一些出现频率较高但语义信息量较少的功能性词汇，诸如 “the”“and”“is”“of” 等。这些词汇可能在不同的文本或人格类型中均广泛存在，故而对于区分性特征的贡献相对有限。剔除这些停用词能够让分析更侧重于那些具有实际意义的关键词，例如名词、动词和形容词等，从而提升分析的有效性。

经过上述环节处理后，剩余的有价值词语将被重新组合成连续的文本串，为后续的研究构建基础。例如，原始语句“I am reading a great book about psychology”经过处

理后可能转化为更为精炼的短语“reading great book psychology”，更准确地反映其核心语义内容。

（3）数据平衡处理

将文本的 MBTI 类型标签（如“INFJ”“ESTP”）转换为数字编码，便于模型算法处理。同时创建双向映射，确保可以在数字和文本标签之间自如转换。由于 MBTI 数据集存在严重的类别不平衡，会导致模型偏向于预测多数类，且对稀有类型的预测准确率可能极低，这对模型性能评估指标会产生误导，使用 RandomOverSampler 复制少数类样本，使每种 MBTI 类型达到相同的样本数量。然后创建一个平衡后的数据集，保存为 CSV 文件，以便后续分析使用。

3.1.3 数据集划分策略

为训练最优模型，本研究采用两阶段数据集划分方案，融合了 K 折交叉验证和传统的训练集-测试集划分方法。

进行 5 步交叉验证，将平衡的 MBTI 数据集随机划分为五个能力相近的子集。在每轮交叉验证中，其中四个子集（约占数据的 80%）用作训练数据，剩余一个子集（约占数据的 20%）用作验证数据。这样能保证数据集中的每个样本都有可能在验证集中出现一次，提高模型评估的稳健性。在整个交叉验证过程中持续观察并记录验证集中表现最佳的模型。

交叉验证完成后，开始第二步。此时整个数据集再次被划分为训练集（占 80%）和测试集（占 20%）。这种拆分是完全独立的，测试集中的数据是全新的未参与过模型训练或参数选择过程。将前一个交叉验证步骤中性能最佳的模型应用于此独立测试集获得最终的性能评估指标。

这种两阶段组合的方法在交叉验证中充分利用数据进行模型选择和参数优化，经过独立测试集确保最终评估结果的客观性和对模型泛化能力的准确评估，可以有效降低过拟合风险，提供更可靠的模型性能评估。

3.2 特征工程

3.2.1 语言学特征分析

（1）词性分布分析

为了探究不同 MBTI 人格类型在语言使用中的语法偏好特征，用语法分布分析法

从语言学角度揭示个体表达风格与思维倾向之间的关系。个体在言语过程中对特定语法类别的选择往往能够反映其认知结构和交际策略。具体实现的时候要先要把每种 MBTI 人格类型对应的文本数据进行标注，利用自然语言处理工具自动识别和标注词语所属的语法类别。然后利用 NLTK 库中的词性标注和统计功能对主要词性的频率进行排序和分析。词性的主要类别包括：名词（例如普通名词、复数名词和专有名词）、动词（涵盖各种时态和语态）、形容词（涵盖比较级和最高级）、副词（也涵盖其各种程度）和代词（例如人称代词、反身代词、指示代词）。

从分析的角度来看，名词的频繁使用通常表明一个人关注事物、概念或实体，其语言表达往往更加客观；动词的使用频率和类型可以揭示一个人更注重行为的动态描述还是状态的表达；如果一个人更喜欢使用形容词，这可能表明他们注重描述对象的特征，并且话语内容更具情感色彩；副词的频繁使用通常出现在那些倾向于详细描述行为模式或状态强度的人身上。就代词而言，它们在交际中往往呈现出个体强调的关系取向和表达重点的差异。




图 3.6 MBTI 词性分布分析

从图 3.6 能看出不同的 MBTI 人格类型在词类使用上呈现出大致一致的整体分布模式，这表明本研究使用的语料库在语言结构方面具有一定的共性。仔细看来，名词的使用频率在所有类型中最高，约占总词汇量的一半至 55%。使用频率第二高的是动词和形容词，而副词和代词的比例相对较小。

整体分布模式虽然相似，但不同类型之间仍存在差异。例如 N 型个体（INFJ、

ENTP、INTJ 等）更频繁地使用形容词，而 S 型个体（ESFJ、ISTJ 等）在使用形容词方面略显保守，更直接、更具体。T 型和 F 型人格也存在差异，前者（ENTJ、ISTP）使用名词的频率略高，后者（ENFJ、ISFP）使用代词的频率更高。

综上，尽管 MBTI 不同类型在词类使用上存在细微差异，但这些差异体现了各自固有的认知风格和表达倾向。上述结果不仅支持了 MBTI 理论关于人格类型和信息加工方式存在系统性差异的假设，也说明在整体相对语言结构稳定的前提下，个体差异仍然可以通过词类的分布体现出来。

（2）论述风格分析

文本结构布局和语言表达的复杂度分析在文本风格分析中至关重要，量化分析不同 MBTI 人格类型的语言表达特征可以探索他们在思维逻辑和沟通倾向方面的潜力。

话语复杂度可以用“平均句长”来衡量，统计所有句子的词数并取平均值。该指标反映个体组织思维的程度。一般长句表明说话者倾向展开多层次的论证或阐述复杂的思想，而简单句子的文本则反映作者注重效率，更加直观。

词汇复杂度可以用“平均词长”来衡量，即文本中所有单词的平均字母或字符数。较长的词认为文本使用更多学术、抽象、专业的词，反之较短的词汇通常易于理解，更注重语言的流畅性和可读性。

为考察词汇丰富度，采用“词汇多样性”指标（类型与词元比率 TTR）来表示不同词汇在总词汇量中所占的比例。数值高意味着说话者的词汇量大，重复的词汇较少，低就表明词汇较集中，这种重复性体现出对特定主题的强调或想要清晰表达的语言风格。

总之对以上三个维度的分析可以建立不同 MBTI 类型的言语风格特征描述，揭示语言表达背后的认知和交际机制。




图 3.7 MBTI 论述风格指标

据图 3.7，MBTI 人格类型在句子长度方面无显著差异。数据显示，ESFJ 型的平均句子长度最长是 12.2 个词，ISTP 型的平均句子长度最短 11 个词左右，“SJ”型（ESTJ、ESFJ）更多使用更复杂的句法结构。各类人格在词长方面具有相似性，平均每个单词约 4 个字母，不同人格基本一致，然而 N 型（INFJ、ENTP、INTP）的平均词长略长，这可能与他们倾向于使用更多抽象词汇有关。词汇丰富度指数显示出不同 MBTI 人格在词汇选择差异不明显，大多数集中在 0.1，ESFP 和 ESTJ 在该指标上略有优势但不明显，本研究使用文本数据过多可能致使整体词汇丰富度偏低，样本量的增加会加大词汇重复的概率，导致该指标的数值下降。

（3）情感倾向分析

用情感分析库（Valence Aware Dictionary and sEntiment Reasoner，VADER）进一步分析不同 MBTI 人格类型的人对情绪表达的偏好和行为模式，VADER 分析生成四个指标，分别评估文本在不同程度上的情绪倾向和强度。

复合情感得分（Compound）是一个标准化的总体情绪指标，由文本中所有词语的情绪强度进行加权计算得出，取值范围从 -1 到 +1。“负面”表示极度负面情绪，“正面”表示极度强烈的正面情绪，“零”表示中性或不明确的情绪状态。分数大于或等于 0.5 表示文本传达正面情绪，0.1 至 0.5 分表示轻度至中度的正面态度，大于 -0.1 且小于 0.1 表示情绪表达相对平衡或模棱两可，小于或等于 -0.1 表示存在不同程度的负面情绪，愤怒、抑郁或批评性内容。

积极情感得分（Positive Score, pos）衡量积极词汇或表达的比例，范围为 0 到 1。值越高积极信息越多，揭示个体在情绪表达中倾向积极态度（乐观、支持或赞同）。

中性情感得分（Neutral Score, neu）衡量中性情绪比例。分数高表明主要是事实陈述、客观描述或技术性语言，情绪不明显。这类内容常以较为理性和信息丰富的方式呈现。

消极情感得分（Negative Score, neg）对应负面情绪元素的比例，值也在 0 到 1 间。较高分表明包含大量负面词汇或负面情绪（批评、接受、帮助），利于关注到文本中负面情绪表达的模式和强度。




图 3.8 MBTI 情感倾向

分析结果图 3.8 可以显示不同 MBTI 类型在表达情感方面的偏好图中展示了四个关键情感指标。

复合情感得分：所有 MBTI 类型都表现出较高的正面情感倾向，得分普遍在 0.75~0.9。其中，ENFJ、ENFP、ESFJ 和 ISFP 类型展示出最高的复合情感得分（约 0.9），而 INTP 和 INTJ 的得分相对较低（约 0.75）。

积极情感得分：所有类型相对一致，大多在 0.15~0.2。ENFP 和 ENFJ 类型表现

出略高的积极情感分数，而其他的相对较低。

中性情感得分：所有类型普遍在 0.7~0.8 之间。ISTJ、ISTP 和 INTJ 类型表现出较高的中性情感得分，而 ENFJ 和 ENFP 则相对较低。

消极情感得分：所有 MBTI 类型都很低，大多在 0.05~0.1 之间。INTP 和 INTP 表现出稍高的消极情感得分，而 ESFJ 相对较低。

（4）时态使用分析

为考察不同 MBTI 人格类型的个体在语言表达中对时间维度运用的偏好和特点，运用 NLP 量化文本中三种主要时态（现在时、过去时和将来时）的出现频率。

对时间使用的定量分析不仅揭示个体关注的时间维度，还能洞察其决策倾向、价值观和沟通模式，结果见图 3.9。




图 3.9 MBTI 时态使用

不同类型的人格在时间选择上呈现出共同的倾向，发现现在时在语言表达上具有显著优势，各类型的使用比例集中在 65%-72%间。ISFP 个体使用现在时的倾向最强，约 72%。其次是 ISFJ 类型，约为 71%。这种分布特征表明他们兼具感觉（S）和情感（F）两种特质。这两种类型能够更加关注实际体验和即时感受，注重当下，更喜欢直接对当前情况做出反应。

按时间使用频率排序，过去时位居第二，占比在 27%到 33%之间，ISTJ 和 INFJ 人格在此方面表现尤为出色（32%-33%），而 ISFP 和 ISFJ 相对较低（27%-28%）。所以 IJ 型结合可能注重反思过去、归类经验。

所有 MBTI 类型基本遵循现在时 > 过去时 > 将来时的基本规律，但不同类型之间的细微差异，反映出他们独特的时间认知方式和表达特点。这些结果为探索人格特质与语言行为模式之间的相关性提供经验。

为了识别、量化每种 MBTI 类型所特有的语言学特征，展现其在词汇选择上的偏好模式，采用了 TF-IDF 技术，并且生成特征词条形图如图 3.10 所示。

图 3.10 MBTI 特征词条形图

N 型（INFJ、ENTP、INTP、INTJ）更多的讨论 MBTI 本身，S 型（ISFP、ESFP）常使用与特定感受相关的词汇，如“pretty”“love”“feel”，他们对感官体验更重视。T 型（ENTJ、ISTP）使用的词汇则更多样，而 F 型（INFP、ENFJ）更强调“feel”“love”“friend”等与情绪和人际关系相关的词汇。J 型（ESTJ、INFJ）“time”一词排名较高，他们重

视计划和时间管理。P 型（ENFP、INTP）词汇分布较为分散，更关注各种可能性。E 型（ENFP、ESTJ）常用“friend”，重视社会关系，而 I 型（INFJ、INTP）频繁使用体现内省和反思特征的词汇。

3.2.2 文本表示模型选择

基于前述语言学特征分析，需要选择适当的文本表示模型，将非结构化文本转换为深度学习算法可处理的数值形式。

（1）文本表示方法

使用序列化表示法，将文本转换为数字序列，这是 NLP 中常见的做法。具体实现是通过 Keras 的 Tokenizer 将原始文本转换为数字序列，每个单词映射到一个唯一的整数 ID，同时设置 20,000 个词的上限，超出范围的低频词会被特殊标记“<OOV>”替代，最后通过 pad_sequences 将所有文本序列标准化为相同长度（500 个词），短序列在后面填充零以保持一致性，这种方法保留了文本的词序信息，适合后续的序列模型处理。

（2）词嵌入模型

使用预训练的 GloVe 词向量，这是一种基于全局词-词共现统计信息的词表示方法。具体使用了“glove.6B.300d.txt”，每个词由 300 维浮点数向量表示，能有效捕捉词语的语义关系和相似性。代码通过构建嵌入矩阵将模型词汇表中的每个词映射到其预训练的 GloVe 向量，未出现在 GloVe 中的词初始化为零向量，并且在模型中设置嵌入层为可训练状态，使词向量能在训练过程中根据具体任务进一步优化。

（3）文本序列表示的生成过程

文本序列表示的生成过程是一个完整的流水线，从原始文本开始，首先从数据集中提取所有帖子文本，然后通过 Tokenizer 学习整个语料库的词汇分布并建立词汇映射表，接着使用 texts_to_sequences 方法将每篇文章转换为对应的数字序列，再通过 pad_sequences 对序列进行长度标准化处理。在模型中，这些整数序列通过嵌入层转换为密集向量表示，每个词转化为 300 维向量，并结合自定义的 Attention 注意力机制来突出序列中重要的词语特征，增强模型对关键信息的识别能力，这种方法结合了序列模型的优势和预训练词向量的语义丰富性，使模型能更好地理解文本含义并预测 MBTI 人格类型。

3.3 模型构建

3.3.1 LSTM 模型设计

长短期记忆网络(LSTM)作为处理序列数据的经典深度学习模型，在本研究中被用作基准模型。

(1) 网络架构

采用顺序建模方法，由多个功能模块级联组成。在输入处理阶段使用词嵌入模块进行编码，词表征使用预先训练的 100 维 GloVe 向量。模型训练过程中词嵌入层的权重保持不变。配置一个包含 128 个隐藏单元的 LSTM 层，仅输出其最终的隐藏状态。为提升模型的泛化能力，在 LSTM 层和第一个全连接网络之后添加概率为 0.3 的 Dropout 层。然后是一个包含 128 个节点的全连接层，使用 ReLU 激活函数。输出层为一个 Softmax 分类器，包含 16 个类别对应 MBTI 人格类型。该架构参数总数为 213 万个，其中可训练参数约 13.5 万个，其余 200 万个参数来自固定的词嵌入矩阵。

(2) 数据处理与训练策略

使用 LabelEncoder 将 MBTI 类型编码为数字，以 8:2 比例分割训练测试集。使用 Tokenizer 将文本转换为数字序列，词汇量限制为 20000。将所有序列填充到固定长度 128。模型学习率设为 0.001，训练使用早停策略，并在训练过程中通过两层 Dropout 和预训练词嵌入来优化模型性能。

(3) 性能分析与结果

从图 3.11 可以看出，训练过程中损失稳定下降，验证准确率始终高于训练准确率，表明模型具有良好的泛化能力。




图 3.11 LSTM 训练结果

最终模型达到 71% 的总体准确率，但在不同 MBTI 类型上表现差异明显。ESFJ、ESFP 和 ESTJ 等类型表现优秀（F1 分数接近 1.0），而 ENFP、INTP 和 INFJ 等类型表现较差（F1 分数低于 0.3）。宏平均和加权平均的精确率、召回率均约为 0.7。这种不均衡的分类效果可能与数据集分布或不同类型的语言特征差异有关。

LSTM 模型作为基准，展示了序列建模在 MBTI 预测任务上的基本性能，为后续改进模型提供了参考点。

3.3.2 Bi-LSTM 模型设计

考虑到单向 LSTM 只能捕捉前向上下文信息的局限性，引入 Bi-LSTM 模型，通过同时考虑前向和后向上下文，提升模型对文本的理解能力。

（1）网络架构

用 Bi-LSTM 层取代原有的单向结构，为了防止训练过程中出现过拟合，在 Bi-LSTM 层之后定义一个随机 dropout 层，dropout 率为 30%，其他同上一个模型。

与标准 LSTM 架构相比，该模型具有两大技术优势：首先，双向循环结构可以捕捉更丰富的上下文信息；其次，动态调整的词向量参数可以针对特定任务优化语义表示。这种自适应机制显著提升了模型在所有专业领域的泛化能力。

（2）数据处理与训练策略

数据预处理流程与之前类似，主要区别在于标签处理，将原始的人格标签编码为数值形式，然后转换为独热向量，训练策略使用验证分割而非之前的测试集验证。

（3）性能分析与结果

由图 3.12 可知，损失稳步下降，准确率有显著提升。




图 3.12 Bi-LSTM 训练结果

训练损失随着训练轮次稳定下降，并且准确率不断提高，训练准确率从约 59%快速提升至 94%，验证数据达到 89%，总体准确率达到 88%。宏平均和加权平均精确率、召回率和 F1 分数均达到 87%，整体表现一致。训练与验证指标之间存在一定差距，表明有轻微过拟合。

所有人格类型的总体准确率达到 88%，有一些类别表现极佳，如 ESFJ、ESFP、ESTJ、ISFJ、ISFP 和 ISTJ 的 F1 分数接近 1.0，但仍有部分类别表现相对较弱，如 INTJ（F1=0.57）和 INTP（F1=0.56）。总体上，外向型和感觉型人格的识别效果优于内向型和直觉型人格。

Bi-LSTM 模型通过双向信息处理有效提升了对上下文的理解，层级预测机制针对 MBTI 的特殊结构进行了优化，使模型在各个维度上都取得了均衡的性能提升。

（4）与 LSTM 模型的比较

相比之前的 LSTM 模型，Bi-LSTM 模型总体准确率从 71%提高到 88%，提升了约 17 个百分点。各类型之间的性能差距缩小，模型收敛更快，在更少的训练轮次内达到更好的性能。

3.3.3 Bi-LSTM+Attention 模型设计

（1）网络架构

区别于上一个模型的改进就是词嵌入层将文本数据转换为 300 维的分布式向量表示，dropout 层的概率设为 0.1，利用注意力权重计算模块自动识别对分类任务重要的文本片段，从而实现自适应的特征聚焦。

（2）数据处理与训练策略

采用 GloVe 预训练词嵌入为词语提供丰富的语义表示，相当于给模型提供了已有的语言知识基础。设置词汇表大小和最大文本长度，确保输入数据的一致性。训练采用 5 折交叉验证提高评估可靠性，并结合早停策略，在验证损失连续 3 个 epoch 无改善时停止训练并恢复最佳权重，有效预防过拟合。每折训练都使用 32 的批量大小，最多运行 10 个 epoch，但实际上因为早停机制，大多数折数在 6-8 个 epoch 时就达到了最佳性能。

（3）性能分析与结果

模型最终的准确率达到 91%，并且根据图 3.13 所示的交叉验证结果，可以看到在训练过程中平均准确率为 $88.86\% \pm 1.48\%$ ，平均损失为 0.4215 ± 0.0274 ，表明分类性

能稳定且误差较小。




图 3.13 Bi-LSTM+Attention 5 折训练曲线

依据图 3.14 所示的 ROC 曲线，可以观察到该模型的平均 AUC 值达到了显著的 0.989。大多数类别的分类效果显著，分类器在准确率、召回率和 F1 得分上均取得接近最大值的数值。分类混淆矩阵的结构也支持这一结论，呈现出明显的占优对角分布，分类的置信度较高。但第 8、9 类样本的识别效果相对不足，F1 得分分别为 0.62 和 0.58，两者之间的混淆判断能力较差。但最终整体准确率仍然保持在 91%。训练过程显示各交叉验证组的学习曲线呈现出相似的趋势，损失函数在初始阶段快速下降，随后逐渐趋于稳定，表现出训练过程模型的鲁棒性和可重复性。




图 3.14 Bi-LSTM+Attention 混淆矩阵、ROC 曲线

（4）与 Bi-LSTM 模型的比较

Bi-LSTM+Attention 模型整体结构更复杂，有着更深层次的结构设计，最明显的就是加入了更多的 Dropout 层和额外的 Dense 层，还更新了词嵌入、早停策略，能够处理更长的文本序列，模型的准确率提升了 3%。

3.3.4 Bi-LSTM+Attention+自适应学习率模型设计

（1）网络架构

Attention 层定义更加完整，包含权重矩阵、偏置向量和注意力计算机制，不只是简单地调用注意力函数，使模型能够更精确地学习文本中的重要部分，将注意力权重直接应用于序列，然后对加权结果进行求和，从而得到一个固定长度的表示。与前一个模型不同，注意力机制直接处理 Bi-LSTM 的输出，没有额外的 LSTM 层，既简化架构也保持了性能。同时调整 Dropout 策略，在不同层使用不同的丢弃率。

（2）数据处理与训练策略

词嵌入维度、最大序列长度和词汇量与前一个模型相同，但训练策略有明显改进，采用自适应学习率策略（Adam 优化器）。Adam 优化器本身就包含自适应学习率机制，能够根据参数的历史梯度自动调整每个参数的学习率，使得训练过程更加平稳高效。早停策略的耐心值从 3 轮减少到 1 轮，并且保存每一折中表现最佳的模型，然后最终评估中使用验证准确率最高的那一个。

（3）性能分析与结果

结果如图 3.15，从总体表现来看，模型的整体准确率达到 97.42%，高于前一个模型的 91%，学习曲线表示模型训练过程稳定。训练损失和验证损失在前两个 epoch 就显著下降，之后逐渐稳定。所有 5 折验证的曲线模式相似，表明模型的训练过程是稳健的。验证准确率快速上升并稳定在约 97% 左右，这与最终的测试准确率一致。




图 3.15 最优模型训练过程

分类报告如图 3.16，结果显示 16 个分类项目的 F1 得分较为稳定，各指标值均大于 0.90。第 4~7 和 12~14 类获得了 1.00 分，分类器在这些类别中表现出优异性能，其精确率和召回率一致。而类别 8~11 的表现稍差，但仍处于良好水平，F1 值分别为 0.94、0.95、0.90 和 0.89。混淆矩阵显示，主对角线上的数值较高，模型能准确识别绝大多数样本，误判主要集中在类别 8~11，可能是由于这些类别在特征空间中的分布比较相似，导致分类边界不清晰，进而影响模型的判别能力。




图 3.16 最优模型的分类报告、混淆矩阵

(4) 与 Bi-LSTM+Attention 模型的比较

准确率提升了近 9 个百分点，自定义注意力机制更精细，训练策略结合了自适应学习率与高效的模型选择方法，进行更全面的维度分析。从学习曲线看，不同折之间的训练过程稳定一致。

3.3.5 传统机器学习模型实现

本研究使用的传统机器学习模型包括 SVM、XGBoost、Logistic Regression、CatBoost、Gradient Boosting、Random Forest 和 Multinomial Naive Bayes，这些对比模型均建立在相同的特征工程基础上，但采用不同的学习算法。




图 3.17 机器学习模型准确率对比

由图 3.17 可知，模型准确率从大到小为，SVM (65.65%)，XGBoost (65.07%)，Logistic Regression (64.73%)，CatBoost (63.46%)，Gradient Boosting (63.05%)，Random Forest (58.56%)，Multinomial Naive Bayes (40.81%)。可知 SVM 模型表现最佳，准确率达到 65.65%，在各类别上也有相对均衡的表现。大多数模型在识别“INFP”“INTP”和“INFJ”类型时表现较好，但在预测“ESFP”“ESTJ”和“ESFJ”等类型时表现较差。“IN”类型（INFJ, INFP, INTJ, INTP）所有模型普遍能较好识别，“ES”类型（ESFJ, ESFP, ESTJ, ESTP）识别难度最大，大多数模型对这些类型的召回率极低。

通过对比分析发现，虽然最佳的传统机器学习模型也能达到一定的性能，但深度学习模型，特别是 Bi-LSTM+Attention+自适应学习率模型，在本研究中处理文本的长距离依赖和复杂语义关系方面具有明显优势。

第四章 实验结果与分析

4.1 评估指标与实验环境

4.1.1 模型评估指标体系

(1) 基础指标

准确率(Accuracy)、精确率(Precision)、召回率(Recall)、F1 分数、宏平均(Macro-average)、加权平均(Weighted average)、支持数(Support)。

(2) 混淆矩阵分析

构建 16×16 的混淆矩阵，全面展示各 MBTI 类型之间的误分情况。通过可视化模型预测与真实标签的对比，直观展现分类性能。分析易混淆的 MBTI 类型对，如 INTJ/INTP、ENFP/ENTP 等。帮助识别模型难以区分的人格类型，揭示人格类型间的相似性和模型的局限性。计算规范化混淆矩阵，消除类别不平衡影响。转换原始计数为比例或概率，使不同规模的类别可比较，更公平地评估模型性能。

基于混淆矩阵派生混淆度和维度错误率，前者量化模型在相似类型间的混淆程度，帮助理解模型的辨别能力；后者评估模型在各 MBTI 维度(E/I, S/N, T/F, J/P)上的错误情况，揭示模型在哪些性格维度上辨别能力较弱。

(3) MBTI 维度多层次评估

针对每个特质维度构建二分类混淆矩阵，算出每个特质维度的分类任务的精确度、召回率和 F1 得分，从多个角度评估模型对每个维度的区分效果。比较每个维度的整体预测准确率和分类指标以了解模型在不同特征维度上的性能差异，还对误分类样本进行可视化和系统分类。

4.1.2 实验环境配置

(1) 硬件环境

处理器：13th Gen Intel(R) Core(TM) i5-1340P 1.90 GHz

内存：16384MB RAM

GPU（平台租赁）：NVIDIA GeForce RTX 3060/ 3090/4090

(2) 软件环境：

操作系统：Windows 11

Python 版本：3.11.5

4.2 模型性能比较

每个模型的总体准确率、精确率、召回率和 F1 值的宏平均值如表 4.1 所示，可知各模型性能呈现明显的梯度上升趋势。

表 4.1 所有模型指标对比

模型	准确率	精确率	召回率	F1 值
Multinomial Naive Bayes	0.41	0.42	0.41	0.32
Random Forest	0.59	0.63	0.59	0.55
Gradient Boosting	0.63	0.63	0.63	0.62
CatBoost	0.63	0.63	0.63	0.62
Logistic Regression	0.65	0.65	0.65	0.63
XGBoost	0.65	0.65	0.65	0.64
SVM	0.66	0.66	0.66	0.65
LSTM	0.71	0.69	0.71	0.69
Bi-LSTM	0.84	0.84	0.84	0.84
Bi-LSTM+Attention	0.91	0.90	0.90	0.90
Bi-LSTM+Attention+自适应学习率 (最优模型)	0.97	0.97	0.97	0.97

机器学习模型中 SVM 表现最佳，准确率达 0.66，各项指标均衡。XGBoost 和 Logistic Regression 紧随其后，准确率均为 0.65。Gradient Boosting 和 CatBoost 性能相当，两者在各项指标上较一致。Random Forest 表现中等，而 Multinomial Naive Bayes 在所有传统模型中表现最差，准确率仅为 0.41。从分类报告中观察，几乎所有模型对 INFP 的召回率都很高，特别是在 Logistic Regression、Random Forest 和 CatBoost 模型中，召回率分别达到 0.85、0.86 和 0.80。INTP、INFJ 在所有模型中都有稳定的良好表现，INTJ 次之。但是 ESFJ、ESFP、ESTJ、ESTP 这些类型在大多数模型中的 F1 值接近 0，较难识别。ISFJ、ISFP 和 ISTJ 等识别效果较差，但在 SVM 和 XGBoost 模型中表现相对好一点。

尽管传统的机器学习方法能够取得一定的效果，但深度学习模型在此任务中表现更好。经过几轮架构细化，模型的预测性能逐步显著的改善，最优模型的预测准确率达到 0.97，比初始 LSTM 基线模型提高了 26 个百分点。关键评价指标也呈现出

持续上升的趋势，证明本研究提出的优化策略对于提高模型整体性能，尤其是在准确率和召回率方面的有效性。

在类型识别效果方面，ESTJ 和 ESFJ 人格类型的辨别准确率始终保持较高水平，相比“IN”类型（INFJ、INFP、INTJ、INTP）的识别效果相对较低，可是在引入注意力计算单元之后，这些性格类型的识别率明显提高。加入双向特征提取机制也带来了模型性能的提升，ENFP 的 F1 值由 0.33 上升到 0.77，ENTP 的相应指数也由 0.26 上升到 0.65。由结果不难得出在本研究背景下，深度学习模型具有更优性能。

4.3 MBTI 维度预测分析

最优模型在 MBTI 四个维度上的准确率非常高：T/F（思考/感受）维度表现最佳，准确率高达 99.85%；N/S（直觉/感觉）维度次之，准确率为 99.07%；J/P（判断/感知）维度准确率为 98.97%；I/E（内向/外向）维度相对较弱，达到了 98.39%。这表明模型不仅在整体 16 种性格类型上表现出色，在每个二分维度上也有较好的区分能力。从图 4.1 可以看出各维度准确率的视觉比较，所有维度的准确率都远高于基线水平。其中的饼图展示了各个维度的错误率，其中 T/F 维度错误率最低，仅为 0.2%。




图 4.1 最优模型的各维度准确率比较

图 4.2 中的维度混淆矩阵进一步证实了这一点，所有四个维度的混淆矩阵都表现出极高的预测准确性，对角线上的值远大于非对角线值。其中 T/F 维度的混淆最少，几乎所有预测都是正确的。




图 4.2 最优模型维度混淆矩阵

图 4.3 展示了每个维度中各类别的精确率、召回率和 F1 得分，所有指标都接近 99%。特别是 T/F 维度中的 F 类（感受型）达到了 100%的精确率，而 T 类（思考型）达到了 100%的召回率，这表明模型对这一维度的判断非常准确。




图 4.3 最优模型各维度的 precision, recall 和 f1-score

第五章 人机交互系统设计与实现

5.1 系统设计目标与架构

5.1.1 系统功能需求分析

为增强研究成果的实用性，设计一个预测 MBTI 人格类型的 Web 应用系统，根据输入的英文内容，分析用户的写作风格和内容，识别其 MBTI 类型。结果是可视化展示，包括各维度的概率分布，再提供完整的 MBTI 人格描述和解释。并且在主题上要求支持暗黑模式切换，提升用户体验。

5.1.2 系统架构设计

采用典型的 Web 应用架构。

前端：HTML、CSS 和 JavaScript 构建的响应式界面

后端：使用 Flask 框架的 Python 应用

模型层：系统使用了深度学习模型（最优模型）

数据存储：无数据库，只是进行实时处理

5.1.3 数据流设计

数据流设计上采用了单向流动模式：用户输入→前端验证→后端处理→模型预测→结果渲染。具体如下：

- （1）用户输入：用户在前端界面输入英文文本
- （2）前端预处理：前端进行字符计数和简单验证
- （3）提交请求：将文本通过 API 发送到后端
- （4）后端处理：后端对文本进行预处理，输入到模型中
- （5）模型预测：模型输出 MBTI 预测结果和各维度概率
- （6）结果返回：后端将结果格式化并返回给前端
- （7）前端展示：前端渲染结果，显示 MBTI 类型、维度描述和概率分布

5.2 前端界面设计与实现

5.2.1 前端交互功能实现

交互设计遵循“以用户为中心”，文本输入监控功能通过 JavaScript 实时捕获用户输入事件，动态更新字符计数器，在提供了即时反馈的基础上，还能够提示系统处理能力的边界，界面如图 5.1 所示。




图 5.1 MBTI 人格类型预测器

为优化用户的等待体验，构建了多层次的反馈机制，包括动态按钮状态、旋转加载符号以及横向进度条，显著缓解用户在操作过程中产生的负面情绪。主题切换设计为位于界面右下角的圆形固定按钮，方便用户操作。该控件以月相图案作为标识，并添加悬停旋转动画，增强交互感知。当用户激活主题切换时，系统同步更新整体配色，并将文本框、信息对话框、概率展示栏等关键元素适配为深色主题，确保界面呈现的一致性。

心理特质分析结果的呈现运用横向渐变进度条，将 MBTI 四个维度的评估结果进行可视化展现。每个维度都配备了独立的信息图谱，并辅以语义化的图标体系，这样的设计不仅增强了各个维度的视觉区分度，也有助于用户理解和记忆。

系统中的动画效果设计主要用于增强关键交互反馈和过渡体验，比如结果区域的淡入动画、卡片的悬停动效、按钮的波纹效果等，CSS 关键帧动画还用于创建加载指示器（spin）和脉冲效果（pulse）。

5.2.2 响应式设计适配

本系统前端界面的构建采纳响应式设计策略，CSS 样式表为关键技术。用 Flexbox 弹性布局方案解决界面组件的自适应布局问题。需以多列形式呈现的内容区域运用 Grid 技术，特别是如 MBTI 人格测试卡片这类复杂组件，实现依据显示设备宽度自动调整列数及内容分布。

在视觉呈现上进行多项优化，科学配置模块间距、卡片内部边距，优化标题字体大小等，提升页面的美观性与信息的可读性。交互控件有效触控区域直径不小于 50 像素，以确保触摸操作的准确性及用户体验。

5.3 后端模型集成与部署

5.3.1 模型转换与优化

首先，设计多种模型加载方式。模型文件支持 .h5（TensorFlow/Keras 标准格式）和 .pkl（Python pickle 序列化格式）两种格式。先尝试按优先级加载不同格式的模型文件，如果都不存在，就根据原模型代码创建一个新的模型架构。

其次，在模型优化方面。使用正则化技术防止过拟合（L2 正则化和 Dropout 层），实现空间 Dropout 和多个 Dropout 层，提高模型的泛化能力。继续添加残差连接，这有助于深层网络的梯度传播，并且使用学习率自定义的 Adam 优化器。

为了适应不同的应用场景，系统实现一个灵活的模型配置系统。配置参数存储在 JSON 文件中，可以通过 API 动态更新。这些配置包括词汇表大小、文本最大长度、嵌入维度等关键参数，使模型能够在不重新部署的情况下进行调整。

5.3.2 API 设计与实现

作为前端与后端模型通信的关键媒介，应用程序接口（API）的设计对保障系统的可用性及可扩展性等有较大影响。核心接口是预测 API，用于接收用户文本，返回结果，这里融合了深度学习与基于规则技术的混合预测方法，根据文本长度、模型预测置信度以及规则的强度等，动态调整这两种方法的权重，期望提高预测的稳定性和精确性。模型状态 API 用于提供关于模型加载状态、相关文件信息和配置参数等详细信息。配置更新 API 允许在不重启服务的前提下动态修改模型配置参数。批量测试 API 支持对多个样本进行批量测试，以评估模型和规则预测的准确性并提供详细分析结果。关键词影响分析 API 用于各关键词对 MBTI 预测结果的影响程度。

第六章 结论与展望

6.1 研究总结

本研究围绕 MBTI 人格类型与语言风格的内在联系展开，在对数据集进行探索和处理的基础上，设计各种深度学习模型进行训练，并且不断优化，最终获得最优模型，同时对比各种机器学习模型来验证最优模型的可用性。并利用最优模型设计能够预测用户 MBTI 人格类型系统。

研究成果有广阔的应用潜力，在个性化推荐系统领域、招聘与团队构建、心理健康监测领域、心理问题预警等方面都具有一定的现实意义。构建的前端系统也增强研究成果的可用性，为成果拓展到商业、教育等领域提供可能。

6.2 局限性

本尽管本研究在 MBTI 人格预测方面取得了显著成果，但仍存在一些局限性，需要在理解和应用研究结果时予以考虑。本研究的模型结果建立在一定的数据集处理的基础上，那么同样的模型在不同的数据集处理策略上表现可能会不同，因此需要继续探究。并且本研究对于语言的限制比较大，只支持英文识别，拓展性有待加强。

6.3 未来研究方向

基于本研究的成果和认识到的局限性，提出以下几个有价值的未来研究方向，以进一步推动 MBTI 人格预测技术的发展和應用：

（1）拓展语言类别，可以对不同的语种进行研究，集成在一个系统上，如此提高系统的可用性和多样性。

（2）模型与算法探索，可以多尝试其他的深度学习模型，或者改进机器学习模型，进行权重集成，并且搭配合适的数据集处理策略，也许能取得一定的效果。

参考文献


- [1] 卡尔·荣格.荣格心理学[M].江西美术出版社:201902.652.
- [2] 蒋永秀.青年 MBTI 社交行为研究[J].新媒体研究,2025,11(04):67-73.
- [3] 王少凡.深度学习技术在自然语言处理中的应用[J].集成电路应用,2025,42(01):196-197.
- [4] 陈壕.基于 MBTI 开展个性化营销: 洞察个性, 赢取人心[J].国际公关,2024,(19):10.
- [5] Yang C, Richard G, Durkin M. The association between Myers-briggs type indicator and psychiatry as the specialty choice [J] . Int J Med Educ, 2016, 8(7): 48-51.
- [6] 毕红梅,甘文轩.青年大学生“MBTI 文化”的检视、生成及引导[J].高校辅导员学刊,2025,17(02):55-61+98.
- [7] King L A. Linguistic styles: language use as an individual difference[J]. Journal of personality and social psychology, 1999, 77(6): 1296-1312.
- [8] Lee C H, Kim K, Seo Y S, et al. The relations between personality and language use[J]. The Journal of general psychology, 2007, 134(4): 405-413.
- [9] Gjurković M, Karan M, Vukojević I, et al. PANDORA Talks: Personality and Demographics on Reddit[C]//9th International Workshop on Natural Language Processing for Social Media. 2021: 138-152.
- [10] 张岩峰,陈长松,杨涛,等.微博用户的个性分类分析[J].计算机工程与科学,2015,37(02):402-409.
- [11] 纪雨.性格驱动的情感分类关键技术研究[D].华东师范大学,2024.
- [12] Cambria E, White B. Jumping NLP curves: A review of natural language processing research[J]. IEEE Computational intelligence magazine, 2014, 9(2): 48-57.
- [13] Tadesse M M, Lin H, Xu B, et al. Personality predictions based on user behavior on the facebook social media platform[J]. IEEE Access, 2018, 6: 61959-61969.
- [14] Tandra T, Suhartono D, Wongso R, et al. Personality prediction system from facebook users[J]. Procedia computer science, 2017, 116: 604-611.
- [15] Gandhi U D, Malarvizhi Kumar P, Chandra Babu G, et al. Sentiment analysis on twitter data by using convolutional neural network (CNN) and long short term memory (LSTM)[J]. Wireless Personal Communications, 2021: 1-10.
- [16] Li Y, Zhu Z, Kong D, et al. EA-LSTM: Evolutionary attention-based LSTM for time series prediction[J]. Knowledge-Based Systems, 2019, 181: 104785.

- [17] Zhang B, Huang Y, Cui W, et al. Psyattention: Psychological attention model for personality detection[J]. arXiv preprint arXiv:2312.00293, 2023.
- [18] 孙丽璐,董森,陈孟维,等.融合多通道信息的社交网络人格预测模型[J].太原理工大学学报,2023,54(03):509-517.
- [19] ZENG H. Research on the Popularity and Impact of the Myers-Briggs Type Indicator on Young People in China[J]. Lecture Notes in Education Psychology and Public Media, 2023, 6: 425-432.
- [20] 顾雪英, 胡滢. MBTI 人格类型量表: 新近发展及应用[J]. 心理科学进展, 2012, 20(10): 1700-1708.
- [21] Argamon S, Dhawle S, Koppel M, et al. Lexical predictors of personality type[C]//Proceedings of the 2005 joint annual meeting of the interface and the classification society of North America. 2005: 1-16.
- [22] Zhang Y, Jin R, Zhou Z H. Understanding bag-of-words model: a statistical framework[J]. International journal of machine learning and cybernetics, 2010, 1: 43-52.
- [23] Salton G, Buckley C. Term-weighting approaches in automatic text retrieval[J]. Information processing & management, 1988, 24(5): 513-523.
- [24] Jurafsky D. Speech & language processing[M]. Pearson Education India, 2000.
- [25] Kaliyar R K. A multi-layer bidirectional transformer encoder for pre-trained word embedding: A survey of bert[C]//2020 10th international conference on cloud computing, data science & engineering (confluence). IEEE, 2020: 336-340.
- [26] Mikolov T, Chen K, Corrado G, et al. Efficient estimation of word representations in vector space[J]. arXiv preprint arXiv:1301.3781, 2013.
- [27] Pennington J, Socher R, Manning C D. Glove: Global vectors for word representation[C]//Proceedings of the 2014 conference on empirical methods in natural language processing (EMNLP). 2014: 1532-1543.
- [28] Bojanowski P, Grave E, Joulin A, et al. Enriching word vectors with subword information[J]. Transactions of the association for computational linguistics, 2017, 5: 135-146.
- [29] Plank B, Hovy D. Personality traits on twitter—or—how to get 1,500 personality tests in a week[C]//Proceedings of the 6th workshop on computational approaches to subjectivity, sentiment and social media analysis. 2015: 92-98.
- [30] Sherstinsky A. Fundamentals of recurrent neural network (RNN) and long short-term memory

- (LSTM) network[J]. *Physica D: Nonlinear Phenomena*, 2020, 404: 132306.
- [31] Werbos P J. Backpropagation through time: what it does and how to do it[J]. *Proceedings of the IEEE*, 1990, 78(10): 1550-1560.
- [32] Zargar S. Introduction to sequence learning models: RNN, LSTM, GRU[J]. Department of Mechanical and Aerospace Engineering, North Carolina State University, 2021.
- [33] Shahid F, Zameer A, Muneeb M. Predictions for COVID-19 with deep learning models of LSTM, GRU and Bi-LSTM[J]. *Chaos, Solitons & Fractals*, 2020, 140: 110212.
- [34] Li Y, Zhu Z, Kong D, et al. EA-LSTM: Evolutionary attention-based LSTM for time series prediction[J]. *Knowledge-Based Systems*, 2019, 181: 104785.
- [35] 石磊, 王毅, 成颖, 等. 自然语言处理中的注意力机制研究综述[J]. *数据分析与知识发现*, 2020, 4(5): 1-14.
- [36] Tuan D P, Ngoc D P. Comparing Machine Translation Accuracy of Attention Models[C]//2020 7th NAFOSTED Conference on Information and Computer Science (NICS). IEEE, 2020: 130-134.
- [37] Haji S H, Abdulazeez A M. Comparison of optimization techniques based on gradient descent algorithm: A review[J]. *PalArch's Journal of Archaeology of Egypt/Egyptology*, 2021, 18(4): 2715-2743.

附 录

附录 1 系统主题



附录 2 系统处理流程

