

doi:10.3969/j.issn.1672-5166.2025.05.03

基于微服务架构的电子病历智能内涵质控系统建设实践

夏大翔^① 张 帧^① 张贝贝^① 苏义武^① 李成伟^① 伍莹莹^{①△}

文章编号: 1672-5166 (2025) 05-695-07 中图分类号: R197.323 文献标志码: A

摘要 **目的** 电子病历的质控是医疗质量管理的关键,传统人工审查耗时且易出错,因此按需开发了基于微服务架构的智能质控系统。**方法** 利用自然语言处理和大语言模型,自动分析病历文本。系统通过医疗质控规则和LoRA微调技术,优化模型对医疗场景的适应性,自动提取质控问题并生成精准建议。微服务架构确保系统灵活可扩展,支持动态加载规则和实时更新模型。**结果** 测试显示,该系统在质控问题识别和分析上比人工审查更快速、准确,显著提升了医疗质量。**结论** 该电子病历智能内涵质控系统在提升质控水平方面成效显著,具有较高应用价值与推广前景。

关键词 微服务架构 电子病历 智能内涵质控 自然语言处理 大语言模型

Construction and Practice of an Intelligent Content Quality Control System for Electronic Medical Records Based on Microservices Architecture

XIA Daxiang, ZHANG Zhen, ZHANG Fang, SU Yiwu, LI Chengwei, WU Yingying

Zhongnan Hospital of Wuhan University, Wuhan 430071, Hubei, China

Abstract **Objective** Ensuring the quality of Electronic Medical Records (EMRs) is vital for healthcare quality management, as conventional manual review methods are laborious and prone to errors. To resolve this issue, a hospital has developed an intelligent quality control system, which is based on a micro-services architecture. **Methods** This system is capable of automatically analyzing EMR texts by leveraging natural language processing and large language models. This system incorporates medical quality control rules and LoRA (Low-Rank Adaptation) fine-tuning techniques, which not only enhance the model's adaptability to clinical scenarios but also enable automatic extraction of quality issues and generation of precise recommendations. The micro-services architecture ensures the system's flexibility and scalability, as it supports dynamic loading of rules and real-time updates of the model. **Results** Tests have shown that the system can identify and analyze quality issues with greater speed and accuracy than manual review, thereby significantly enhancing healthcare quality. **Conclusion** The intelligent EMR quality control system

基金项目: 武汉大学医院管理研究所项目“基于分级管理的临床路径上报系统设计与实现”

①武汉大学中南医院, 湖北省武汉市, 430071

作者简介: 夏大翔 (1985—), 男, 学士, 工程师; 研究方向: 医院信息化、区域卫生信息化; E-mail: xdx1219@163.com

通信作者: 伍莹莹 (1992—), 女, 学士, 工程师; 研究方向: 医院信息管理、医疗信息技术; E-mail: 2669502529@qq.com

△通信作者

has proven to be highly effective in elevating quality control standards, showcasing substantial application value and broad prospects for widespread adoption.

Keywords micro-services architecture; electronic medical records; intelligent content quality control; natural language processing; large language models

0 引言

电子病历是医疗信息化的核心载体，病历文本质量直接影响临床决策、安全与可追溯性^[1]。随着医院接诊患者人数增长与临床诊疗过程的复杂性升高，人工质控在覆盖与时效上受限，且受经验差异影响难以保证跨疾病、跨科室的质控一致性^[2]。近年的自然语言处理技术与大语言模型在医学文本理解上进展明显，可实现临床业务逻辑的深度理解。同时，通过微服务的解耦、弹性与可观测性亦符合医院复杂场景与监管演进^[3-4]。据此，本文提出并在院内落地“微服务+大语言模型”病历质控系统，以大语言模型为语义引擎，配合 LoRA 微调与规则协同构建病历质控计算引擎，并引入奖励建模与对抗训练抑制幻觉，提升系统整体可靠性，最终在院内算

力与信息系统的融合下，实现病案监管环节的智能化能力提升^[5-6]。

1 系统架构设计

系统采用微服务架构并遵循领域驱动设计，将病历接入与管理、语义解析、规则与评分、建议与闭环反馈、统计可视化、模型与规则配置等能力解耦为“单一职责”的服务，通过轻量级 API 通信、服务注册发现与配置中心实现松耦合协作与故障隔离，结合断路器等模式支撑弹性伸缩与异常降级，见图 1。

技术栈围绕“容器化编排—统一接入—异步解耦—多模存储—可观测治理”构建。各服务以 Docker 交付、由 Kubernetes 按 QPS 水平扩展。接入侧用 Spring Cloud Gateway 统一鉴权、限流与协议转换，服务间



图 1 电子病历智能内涵质控系统辅助计算架构

依注册发现与配置中心实现环境隔离与灰度发布。异步层以 Kafka 承载事件流,数据层用 Oracle 管理事务与评分, S3 兼容对象存储保存原文/影像, Milvus 提供向量检索与证据回溯,以 Neo4j 表达术语关系并对接 SNOMEDCT、ICD 保证一致性^[7-8]。可观测性采用 Prometheus 的指标告警与容量预测。安全侧通过统一身份、细粒度权限、全链路 TLS、脱敏与审计日志,形成低耦合、可审计的系统架构^[9]。

模型规则协同采取“生成+校验”双通道:模型层基于预训练医疗大语言模型,使用 LoRA 进行领域适配并在推理容器启动时热挂载权重。结合 PPO 与对抗训练抑制幻觉,将“正确性、完整性、可执行性”纳入奖励,使输出贴合病历书写基本规范与院内制度^[10]。规则层以 Drools 版本化管理并区分强制规则与参考规则,支持时间窗、阈值与跨文档一致性校验,在模型完成语义分析与建议生成后执行最终合规校验,以在保证高召回率的同时控制假阳性误报^[11-13]。

2 关键技术实现

2.1 大语言模型架构

本研究采用解码器式 Transformer 作为语义解析与建议生成的核心架构,通过多头自注意力在长病历文本上建立全局依赖,并借助残差连接、层归一化与自回归训练获得稳定的生成与推理能力^[14]。为满足长序列与跨段一致性,模型结合相对、旋转位置编码与高效注意力以降低计算复杂度。在通用预训练之后采用领域微调,将知识迁移至病历内涵质控场景,使“缺陷识别—证据抽取—建议生成”的端到端流程在准确性与时延之间取得平衡。

2.2 基座大模型

基座模型为 Qwen2.5-14B,根据官方文档,当前模型总参数约 147 亿,支持最长 128K 上下文^[15]。其预训练覆盖多语种与代码语料、规模约 18 万亿 token,以 Apache-2.0 许可提供基础与指令微调两类模型版

本,便于院内合规部署与定制场景再训练。

2.3 LoRA 微调技术

在有限算力条件下,研究采用 LoRA 在注意力与前馈层加入低秩适配器,冻结基座权重,仅训练小规模矩阵以降低显存与计算开销^[16]。计算架构建设基于 $2 \times A800-80\text{ GB}$,结合混合精度与梯度累积,设 $r=16$,并配合 8-bit 权重量化与逐层冻结,将微调峰值显存由约 68 GB 降至约 23 GB,约 4 小时可完成一轮增量训练。同时,研究团队建立了“错判样例收集—人工标注—提示生成—语料回注”的业务场景应用闭环。

整体计算架构采用参数高效的 LoRA (low-rank adaptation) 进行微调。鉴于大规模语言模型的权重规模庞大,全量微调会显著抬高显存与计算成本。LoRA 在若干关键线性映射处引入低秩适配分支,冻结基座权重,仅训练新增的少量参数,由此在保持主干表示能力的前提下,将可训练参数量与训练时延有效压缩,满足院内受限算力与时效约束。

实现策略上,基座模型保持冻结,仅在注意力与前馈子层的线性映射位置启用 LoRA 适配。适配秩、学习率、批大小与训练轮数等超参数通过小规模验证集实验选取,并结合权重衰减、适配分支的正则化与早停策略抑制过拟合。训练过程采用混合精度与梯度累积以降低显存占用,推理路径与接口形态不变,便于在现有系统内无缝部署。

在“病历内涵质控”的判别子任务中,模型对输入文本输出各质控问题类别的预测分布,训练目标为最小化交叉熵,以提升对真实类别的区分度。优化过程采用一阶方法 (AdamW),配合线性预热与分段/余弦式学习率退火、梯度裁剪与权重衰减等稳定化手段;阈值与类别不均衡处理(如损失重加权或采样策略)依据验证集表现确定。参数更新遵循标准的反向传播流程,无需额外的特殊变体。

在“质控建议”生成子任务中,为强化建议的准确性、完整性与可操作性,在监督微调基础上引入轻量级

强化学习进行奖励对齐：将当前病历与已生成内容视为状态，生成的建议视为动作，依据医学正确性、证据指向性与可执行性构建组合奖励。优化采用策略梯度类方法，并通过散度约束 (kullback-leibler, KL)、基线校正与采样温度控制抑制训练震荡；同时以验证集上的人工标注与自动指标联合校准奖励刻度，保障优化方向与临床期望一致。

基于以上模型微调过程，让 LoRA 的参数高效微调与奖励对齐的轻量级强化学习相结合，在不增加显著资源消耗的前提下，同时提升了质控问题判别与质控建议生成的有效性与实用性；方法对算力与部署环境的要求可控，适配医院内网场景的长期运行与维护。

2.4 PPO 强化学习算法

强化学习阶段选用基于策略梯度的近端策略优化 (proximal policy optimization, PPO)。该方法以“受控更新”为核心，在试探—反馈的迭代过程中对旧策略之间的更新幅度设置显式限制，以减少训练震荡与性能回退，同时保留足够的改进幅，兼顾稳定性与样本效率。

训练流程采用 on-policy 采样与小批量多轮更新：由当前策略生成滚动数据，使用广义优势估计构造低方差的优势信号，并以值函数作为基线以进一步降低方差。在策略更新时引入比率裁剪与目标 KL 监控 / 惩罚，确保更新落在“信任域”附近。配合熵奖励维持适度探索，梯度裁剪、学习率预热与退火、权重衰减等稳定化措施共同抑制数值发散与过拟合。达到预设的 KL 目标或当验证集上的综合奖励不再提升时提前停止，以避免过度优化。

在病历内涵质控场景中，状态定义为“当前病历文本 + 已生成的建议前缀”，动作为“下一步质控建议的生成”，在实现上以逐标记解码实现逐步决策。奖励函数面向临床可用性设计为加权组合。(1) 准确性：医学事实正确、与已知证据一致、不产生虚构内容。(2) 完整性：覆盖关键要点、避免信息遗漏或自相矛盾。(3) 可

操作性：表述清晰、可执行、具可审计性。(4) 规范性与安全性：遵循格式与合规要求、避免不当建议。

为抑制冗长与空洞生成，加入轻度长度正则与重复惩罚；奖励刻度通过标注集评分、规则打分与小规模人工复核联合校准，使优化方向与临床预期一致。

与前述 LoRA 参数高效微调衔接时，基座权重保持冻结，仅对适配分支进行策略更新；训练采用混合精度与梯度累积以控制显存占用，推理路径与接口形态保持不变，便于在院内环境部署。经由上述设置，PPO 在保证训练可控性的同时，提升了质控建议的准确性、完整性与可操作性，并维持稳定的收敛与复现实验表现。

2.5 训练数据与增强策略

为降低幻觉并适配跨科室差异，研究使用同义改写、句式变换等方式扩展“正确 / 错误”数据样本。推理结果通过规则引擎与术语审核的双重校验，对证据不足或不合规输出进行回退、重写或屏蔽。最终训练数据约 6 万份病历，覆盖院内 30 多个内外科室，病例诊断涵盖 400 多个病种。所有数据由临床专家与病案人员联合标注 37 类质控标签，正负样本均衡，Cohen's $\kappa > 0.85$ ，并最终按 85/15 的比例划分训练集与测试集。

2.6 量化评估体系

为了定量评估模型在病历内涵质控中的表现，病案质量监管部门结合病历质控需求提出了以下评价指标。对于质控问题的量化指标评价，可通过精度 (precision)、召回率 (recall) 和 F1 分数 (F1-score) 进行衡量：

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

$$F1 - score = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

其中，TP 为正确识别的质控问题数，FP 为误报数，FN 为漏报数。这一公式直接反映了模型在微调后计算模型对病历文本的质控规则解析能力。

目前,武汉大学中南医院(以下简称“本院”)基于大语言模型构建的质控引擎已正式上线运行,现已覆盖37个质控点。通过为期一周的系统运行测试,每天随机抽取10份质控结果进行人工复核,其识别精度表现良好:质控准确率为0.9976,质控召回率为0.9842, F1分数为0.9909。

其次,对于质控建议的准确性(accuracy)由正确的质控建议(correct suggestions)与所有质控建议(total suggestions)计算,可定义为:

$$Accuracy = \frac{Correct\ Suggestions}{Total\ Suggestions}$$

研究团队与病案室、临床医生共同整理通过人工校验的质控数据集,并以此作为金标准,对质控建议的准确性评估结果良好:正确的质控建议为1844,所有质控建议为1850,准确性为0.997。

通过以上人工校验时的人工耗时评估效率提升情况,可通过如下公式计算效率提升情况。

$$Efficiency\ Gain = \frac{Manual\ Review\ Time - System\ Review\ Time}{Manual\ Review\ Time} \times 100\%$$

结果表明,平均单个质控的人工评审耗时(Manual Review Time)为27.56s,平均单个质控的机器评审耗时(Manual Review Time)为1.35s,效率提升(Efficiency Gain)为95.10%。

传统规则质控以序列标注抽取实体,配合正则与业务逻辑对齐病历规范与ICD,最终由规则解释器告警。该模式依赖人工规则,跨科室与新病种覆盖不足,新增质控点需反复调试、维护成本高。本研究的LoRA+PPO端到端方案直接完成“质控—证据—建议”,误报/漏报约为规则方案的一半,时延显著降低。

2.7 整体架构协同计算流

面向病历内涵质控,协同计算围绕“语义生成—规则校验—闭环反馈”展开。临床文书保存后,经统一接入完成归一化与脱敏,索引写入关系型数据库、原文归档至对象存储,并由消息队列触发后续解析。语义解析服务调用经LoRA适配的基座大模型对全文通读。借助

向量检索引擎在院内历史病例中召回相似语句,并结合术语知识库完成诊断、手术与时间点的标准化映射。一次推理生成“质控点候选—证据片段—建议草稿”,并标注证据出处,便于临床核对。随后进入规则阶段:规则引擎依据病历书写基本规范及院内制度,对时限、必备要素与跨文书一致性进行校验,并与模型置信度联合给出“通过/预警/返修”及可审计解释。结论与证据回写数据库并推送至科室工作台。医生的采纳或申诉形成反馈样本,进入持续学习链路,用于小规模适配参数与阈值的增量更新,使系统随新规范与新病种迭代。全流程运行于容器编排平台,由指标监控系统持续观测时延与正确率,出现波动时通过限流与降级保障质控服务的稳定可用。

3 系统应用场景

系统以“大语言模型语义解析+规则引擎”为核心,形成“环节质控—终末质控—统计评估”的病历管理闭环流程。环节质控依据病历书写基本规范和院内制度实时监控时限与内容,提供系统层面的多渠道提醒。同时系统定时检查新增病历,并生成包含质控证据与修改建议的问题报告。质控规则按强制规则与参考规则的维度,在出院、归档等关键节点进行分类,对签名、会诊、手术等要素做一致性与完整性校验,未达标即预警提示。终末质控在归档前通过评分规则进行缺陷检测与分级,经人机协同复核后触发返修与评分修正。医生通过平台完成病历修改或质控申诉,并由病案室工作人员完成人工复审,保证结果可追溯、可审计。统计模块基于评分与缺陷数据输出核心指标与趋势,并按科室、文书类型给出高频缺陷与预警,支持到科室、医疗组、个人的评比与绩效考核,推动病案质量从被动纠错到主动改进。

4 系统运行效果

本研究基于本院现有的病历质量控制体系,设计并构建了一套综合性的病历质控规则库,涵盖病历书写规

范、医疗核心制度执行情况及诊疗逻辑合理性等多个维度，实现对病历质量的全方位监督与管理。规则库的构建采取专家经验和智能算法协同的模式，一方面由医学专家团队深入分析并制定基础质控规则，另一方面通过大语言模型技术自动生成具有较高灵活性的条件质控规则。具体规则数量的构成情况，见表 1。

表 1 病历质控规则库构成情况统计

序号	规则类型	规则数量 / 条
1	专家人工制定基础规则	100
2	大语言模型自动生成条件规则	37
合计		137

发，并通过 PPO 优化使质控问题的修正建议更贴合临床语境，减少二次校正。后续研究工作组将持续改进，重点推进医学影像数据与影像报告间的内涵质控，内涵质控的过程中的思维链计算能力，以及将当前病例质控

质控引擎构建后，系统以历史病历为训练集，采用“规则一大语言模型”协同优化，持续学习临床数据并进行质控问题分析，并按趋势定期更新规则与模型，并同步校准评分权重与阈值，以适应病案管理制度变化。架构按业务边界微服务化解耦，病历解析、规则匹配、建议生成与反馈处理等模块可独立部署与弹性扩缩。批量任务可单独扩展质控计算量，且不影响其他服务，并支持独立开发、灰度发布与热更新。依托可观测与故障隔离机制，系统实施全链路日志与指标监控与告警，快速定位瓶颈并避免级联故障。上线初期将系统质控结果与人工质控对照分析，迭代优化规则与参数后进入稳定运行，系统运行前后对比指标变化见表 2。

系统的实际应用结果表明，质控系统显著提高了病历内容的完整性与准确性，并显著减少了问题病历的发现与处理时间，极大地提升了医院病历质量控制工作的效率和效果。

5 整体架构优势

在不重复前述架构细节的前提下，LoRA 将可训练参数控制在约 0.8%，微调峰值显存较全参方案下降约

表 2 系统运行前后病历质控关键指标对比

序号	质控指标	系统运行前	系统运行后	提升比例
1	每日质控提示信息量	超过 10 万条	约 5 万条	减少约 50%
2	病历内容完整性	—	提高约 50%	提高约 50%

70%，单轮耗时缩短逾 60%。配合 PPO 的策略裁剪与奖励稀疏化，进一步降低推理期显存与 CPU 占用，在维持 F1 的情况下将单份病历处理时延压至传统规则引擎的约 10%。运维方面，LoRA 热挂载叠加灰度 / 滚动发布，使新质控点从配置到验证由“周”级缩至“小时”级，跨科室规则平均迭代次数减少约 60%，并发 >5000 次 / 分时，核心实例自动扩至基线的 8~10 倍，

P99<200ms。同时，系统做到了故障隔离避免级联，业务可用性约 99.9%。

6 结束语

本研究在武汉大学中南医院部署并运行“微服务 + LoRA+PPO”电子病历内涵质控系统，完成从实时质控到问题修正的自动化管控。在有限算力下支撑稳定高并

引入持续学习机制,并开展多中心外部验证。本研究基于当前计算框架为电子病历内涵质控提供了一条可复制、可扩展的工程化路径,可为医院质量治理的标准化与精细化提供技术支撑。■

参考文献

- [1] PATTAR B S B, ACKROYD A, SEVINC E, et al. Electronic Health Record Interventions to Reduce Risk of Hospital Readmissions: A Systematic Review and Meta-analysis of Randomized Clinical Trials[J]. JAMA Network Open, 2025, 8(7): e2521785.
- [2] MODI S, FELDMAN S S, BERNER E S, et al. Value of Electronic Health Records Measured Using Financial and Clinical Outcomes: Quantitative Study[J]. JMIR Medical Informatics, 2024, 12: e52524. doi: 10.2196/52524.
- [3] HOSSAIN E, RANA R, HIGGINS N, et al. Natural Language Processing in Electronic Health Records in relation to healthcare decision-making: A systematic review[J/OL]. Computers in Biology and Medicine, 2023, 155: 106649.
- [4] YANG X, CHEN A K, POURNEJATIAN N, et al. A large language model for electronic health records[J/OL]. npj Digital Medicine, 2022, 5(1): 194.
- [5] HU E, SU P, QIU Y, et al. LoRA: Low-Rank Adaptation of Large Language Models[EB/OL]. arXiv preprint arXiv: 2106.09685, 2021[2025-04-08]. <https://arxiv.org/abs/2106.09685>.
- [6] Kaufmann T, Weng P, Bengs V, Hüllermeier E. A Survey of Reinforcement Learning from Human Feedback[J]. Transactions on Machine Learning Research (TMLR), 2025.
- [7] 葛萌, 李闯男, 欧阳宏基. 基于 Spring Cloud 的微服务架构的应用与实现[J]. 现代信息科技, 2021, 5(19): 23-26.
- [8] NISWAR M, ARISANDY SAFRUDDIN R, BUSTAMIN A, et al. Performance evaluation of microservices communication with REST, GraphQL, and gRPC[J/OL]. International Journal of Electronics and Telecommunications, 2024, 70(2): 429-436.
- [9] HUI M X, WANG L, LI H, et al. Unveiling the Microservices Testing Methods, Challenges, and Solutions: A Systematic Mapping Study[J]. Journal of Systems and Software, 2025: 112232. doi: 10.1016/j.jss.2024.112232.
- [10] 吴春志, 赵玉龙, 刘鑫, 等. 大语言模型微调方法研究综述[J]. 中文信息学报, 2025, 39(2): 1-26.
- [11] 李世豪. 基于规则的病案质控系统的开发与应用[D]. 海口: 海南大学, 2024. DOI: 10.27073/d.cnki.ghadu.2024.000642.
- [12] 江鑫柱, 骆晓琳, 陈巧莉. 公立医院高质量发展背景下电子病历系统质控体系建设的探讨[J]. 现代医院, 2025, 25(3): 435-437.
- [13] 东振彩. 高质量发展背景下医院电子病历质控体系建设的思考[J]. 现代医院, 2025, 25(1): 65-67, 71.
- [14] ZHAO W X, ZHOU K, LI J, et al. A Survey of Large Language Models[J/OL]. arXiv preprint arXiv: 2303.18223, 2023. doi: 10.48550/arXiv.2303.18223.
- [15] QWEN TEAM. Qwen/Qwen2.5-14B-Instruct[EB/OL]. 2025-07-21[2025-09-19]. <https://huggingface.co/Qwen/Qwen2.5-14B-Instruct>.
- [16] HU E, SHEN Y, WALLIS P, et al. LoRA: Low-Rank Adaptation of Large Language Models[EB/OL]. arXiv preprint arXiv: 2106.09685.

[收稿日期: 2025-04-24 修回日期: 2025-09-14]

(编辑: 蒋桂霞)